

2023-2024 学年期末考试真题中文解析

第 1 题 模糊逻辑真值计算

题意概述

已知两个模糊集合

$$\mu(A) = 0.4/0.5 + 0.7/0.8 + 0.6/0.9$$

$$\mu(B) = 0.5/0.5 + 0.6/0.8 + 0.7/0.9$$

要求计算：

1. $\neg A$
2. $A \wedge B$
3. $A \vee B$
4. $A \rightarrow B$
5. $B \rightarrow A$

对应知识点

这一题对应不确定性一章中的**模糊集合与模糊逻辑**。重点考的是模糊逻辑中几种最基本的运算规则，属于非常典型的概念加计算题。

解析

先看记号。像

$$0.4/0.5 + 0.7/0.8 + 0.6/0.9$$

表示的是：在论域元素 0.5, 0.8, 0.9 这三个点上，集合 A 的隶属度分别是 0.4, 0.7, 0.6。

也就是说，

$$\mu_A(0.5) = 0.4, \quad \mu_A(0.8) = 0.7, \quad \mu_A(0.9) = 0.6$$

$$\mu_B(0.5) = 0.5, \quad \mu_B(0.8) = 0.6, \quad \mu_B(0.9) = 0.7$$

接下来逐点计算即可。

对于补集，采用

$$\mu_{\neg A}(x) = 1 - \mu_A(x)$$

因此:

$$\mu_{\neg A}(0.5) = 1 - 0.4 = 0.6$$

$$\mu_{\neg A}(0.8) = 1 - 0.7 = 0.3$$

$$\mu_{\neg A}(0.9) = 1 - 0.6 = 0.4$$

所以

$$\neg A = 0.6/0.5 + 0.3/0.8 + 0.4/0.9$$

对于交, 通常采用最小值规则:

$$\mu_{A \wedge B}(x) = \min(\mu_A(x), \mu_B(x))$$

因此:

$$\mu_{A \wedge B}(0.5) = \min(0.4, 0.5) = 0.4$$

$$\mu_{A \wedge B}(0.8) = \min(0.7, 0.6) = 0.6$$

$$\mu_{A \wedge B}(0.9) = \min(0.6, 0.7) = 0.6$$

所以

$$A \wedge B = 0.4/0.5 + 0.6/0.8 + 0.6/0.9$$

对于并, 通常采用最大值规则:

$$\mu_{A \vee B}(x) = \max(\mu_A(x), \mu_B(x))$$

于是:

$$\mu_{A \vee B}(0.5) = 0.5, \quad \mu_{A \vee B}(0.8) = 0.7, \quad \mu_{A \vee B}(0.9) = 0.7$$

所以

$$A \vee B = 0.5/0.5 + 0.7/0.8 + 0.7/0.9$$

对于蕴含，这道题采用的是模糊逻辑里常见的一种定义：

$$\mu_{A \rightarrow B}(x) = \max(1 - \mu_A(x), \mu_B(x))$$

逐点计算：

在 $x = 0.5$ 处，

$$\max(1 - 0.4, 0.5) = \max(0.6, 0.5) = 0.6$$

在 $x = 0.8$ 处，

$$\max(1 - 0.7, 0.6) = \max(0.3, 0.6) = 0.6$$

在 $x = 0.9$ 处，

$$\max(1 - 0.6, 0.7) = \max(0.4, 0.7) = 0.7$$

因此

$$A \rightarrow B = 0.6/0.5 + 0.6/0.8 + 0.7/0.9$$

同理，

$$\mu_{B \rightarrow A}(x) = \max(1 - \mu_B(x), \mu_A(x))$$

于是：

$$\mu_{B \rightarrow A}(0.5) = \max(0.5, 0.4) = 0.5$$

$$\mu_{B \rightarrow A}(0.8) = \max(0.4, 0.7) = 0.7$$

$$\mu_{B \rightarrow A}(0.9) = \max(0.3, 0.6) = 0.6$$

所以

$$B \rightarrow A = 0.5/0.5 + 0.7/0.8 + 0.6/0.9$$

小结

这道题并不难，关键是记住四条基本规则：补集取 $1 - \mu$ ，交取 $\min$ ，并取 $\max$ ，蕴含常用 $\max(1 - a, b)$ 。考试时最容易错的是把交并和蕴含公式混掉，因此一定要在草稿上先写清运算定义，再逐点代入。

第 2 题 CLIPS 规则书写

题意概述

已知一个 person 模板，包含 name、age、occupation、nationality 四个槽位。要求分别写出：

1. 匹配“来自美国且职业是程序员”的人；
2. 匹配“年龄在 20 到 25 岁之间且国籍是 French 或 German”的人；
3. 把“Chinese”国籍的人的年龄增加 5 岁。

对应知识点

这道题对应第八章 CLIPS 与基于规则的专家系统。重点在于：

1. 看懂 deftemplate 的槽位结构；
2. 会在规则左部写模式匹配；
3. 会用约束表达数值范围与候选取值；
4. 会在右部使用 modify 修改事实。

解析

这道题本质上是在考“会不会把自然语言条件翻译成 CLIPS 模式”。

第一问最直接，只要在 person 模式里同时写出两个槽位约束即可。一个比较自然的写法是：

```
(defrule us-programmer
  (person (name ?nm)
           (occupation computer-programmer)
           (nationality U.S.))
  =>
  (printout t ?nm " is from the U.S. and is a computer programmer." crlf))
```

这里需要注意：?nm 是变量，用来把姓名绑定下来。

第二问考的是约束写法。年龄在 20 到 25 岁之间，意味着既要满足大于等于 20，也要满足小于等于 25；国籍是 French 或 German，意味着是一个析取条件。可以写成：

```
(defrule young-french-or-german
  (person (name ?nm)
           (age ?a &(>= ?a 20) &(<= ?a 25))
           (nationality ?nat &(or (eq ?nat French) (eq ?nat German))))
  =>
  (printout t ?nm " matches the condition." crlf))
```

这里最需要记住的是 ?a &(...) 这种写法。它表示先用变量 ?a 绑定年龄值，再立即对它施加谓词约束。国籍条件中的 or 也是同理。

第三问要修改事实，关键在于：若要使用 `modify`，必须先把被修改的那条事实的**事实地址**绑定下来。例如：

```
(defrule increase-age-for-chinese
  ?p <- (person (nationality Chinese)
               (age ?a))
  =>
  (modify ?p (age (+ ?a 5))))
```

这里的 `?p <-` 非常重要。它不是多余写法，而是为了让 `modify` 知道“到底要改哪一条事实”。如果没有这一步，就只有年龄值，没有事实地址，系统无法知道该修改哪条 `person` 记录。

小结

这一题看起来像写代码，其实核心还是知识表达。把自然语言条件拆成“槽位约束 + 变量绑定 + 右部动作”即可。真正容易丢分的地方不是逻辑，而是语法细节，例如忘了绑定事实地址却直接 `modify`，或者把两个年龄条件写成了互不相连的普通文本。

第 3 题 归结反驳证明

题意概述

已知：

1. 每个投资者都买了股票或债券；
2. 如果道琼斯指数崩盘，那么所有不是黄金股的股票都会下跌；
3. 如果国库券利率上升，那么所有债券都会下跌；
4. 每个投资者只要买到了会下跌的东西，就不会快乐。

要求证明：

如果道琼斯指数崩盘且国库券利率上升，那么任何快乐的投资者一定买了某个黄金股。

对应知识点

这道题对应第七章逻辑与 Prolog，属于最经典、也最重要的一类题：**自然语言形式化 + 子句化 + 归结反驳**。这正是整门课里最需要熟练掌握的逻辑大题之一。

第一步：把命题翻译成一阶逻辑

先引入谓词：

- `Investor(x)`： x 是投资者。
- `Stock(y)`： y 是股票。
- `Bond(y)`： y 是债券。
- `Gold(y)`： y 是黄金股。
- `Buy(x,y)`： x 买了 y 。
- `Fall(y)`： y 下跌。
- `Happy(x)`： x 快乐。
- `DJCrash`：道琼斯指数崩盘。
- `TBRise`：国库券利率上升。

则四条前提可写为：

$$\forall x (Investor(x) \rightarrow \exists y ((Stock(y) \vee Bond(y)) \wedge Buy(x, y)))$$

$$DJCrash \rightarrow \forall y ((Stock(y) \wedge \neg Gold(y)) \rightarrow Fall(y))$$

$$TBRise \rightarrow \forall y (Bond(y) \rightarrow Fall(y))$$

$$\forall x \forall y (Investor(x) \wedge Buy(x, y) \wedge Fall(y) \rightarrow \neg Happy(x))$$

目标结论是：

$$(DJCrash \wedge TBRise) \rightarrow \forall x ((Investor(x) \wedge Happy(x)) \rightarrow \exists y (Gold(y) \wedge Buy(x, y)))$$

第二步：做归结反驳，先否定结论

归结证明不是直接证结论，而是“前提成立且结论为假”推出矛盾。

因此否定结论得到：

$$DJCrash \wedge TBRise \wedge \exists x (Investor(x) \wedge Happy(x) \wedge \forall y (\neg Gold(y) \vee \neg Buy(x, y)))$$

直观上，这表示：确实发生了崩盘和利率上升，并且存在某个快乐投资者 a ，但他没有买任何黄金股。

令这个反例个体为 a ，则得到：

$$Investor(a), \quad Happy(a), \quad \forall y (\neg Gold(y) \vee \neg Buy(a, y))$$

第三步：化为子句形式

第一条前提中有存在量词，需要 Skolem 化。令 $f(x)$ 表示“投资者 x 买到的某个东西”，则得到两条子句：

$$\neg Investor(x) \vee Stock(f(x)) \vee Bond(f(x))$$

$$\neg Investor(x) \vee Buy(x, f(x))$$

其余前提化为子句后分别是：

$$\neg DJCrash \vee \neg Stock(y) \vee Gold(y) \vee Fall(y)$$

$$\neg TBRise \vee \neg Bond(y) \vee Fall(y)$$

$$\neg Investor(x) \vee \neg Buy(x, y) \vee \neg Fall(y) \vee \neg Happy(x)$$

由否定结论得到：

$$DJCrash$$

$$TBRise$$

$$Investor(a)$$

$$Happy(a)$$

$$\neg Gold(y) \vee \neg Buy(a, y)$$

第四步：进行归结

先由

$$\neg Investor(x) \vee Stock(f(x)) \vee Bond(f(x))$$

和

$$Investor(a)$$

归结，得

$$Stock(f(a)) \vee Bond(f(a))$$

这说明反例投资者 a 买的那个东西，要么是股票，要么是债券。

再由

$$\neg Investor(x) \vee Buy(x, f(x))$$

和

$$Investor(a)$$

归结, 得

$$Buy(a, f(a))$$

然后把

$$\neg Gold(y) \vee \neg Buy(a, y)$$

中的 y 用 $f(a)$ 实例化, 并结合 $Buy(a, f(a))$, 得到

$$\neg Gold(f(a))$$

接着看股票那条。由

$$\neg DJCrash \vee \neg Stock(y) \vee Gold(y) \vee Fall(y)$$

和

$$DJCrash$$

归结, 得到

$$\neg Stock(y) \vee Gold(y) \vee Fall(y)$$

再取 $y = f(a)$, 并与 $\neg Gold(f(a))$ 归结, 得到

$$\neg Stock(f(a)) \vee Fall(f(a))$$

再看债券那条。由

$$\neg TBRise \vee \neg Bond(y) \vee Fall(y)$$

和

$$TBRise$$

归结, 得

$$\neg Bond(y) \vee Fall(y)$$

再取 $y = f(a)$, 得

$$\neg Bond(f(a)) \vee Fall(f(a))$$

另一方面, 由

$$\neg Investor(x) \vee \neg Buy(x, y) \vee \neg Fall(y) \vee \neg Happy(x)$$

分别代入 $x = a$ 、 $y = f(a)$, 并结合

$$Investor(a), \quad Buy(a, f(a)), \quad Happy(a)$$

可归结出

$$\neg Fall(f(a))$$

于是:

- 用 $\neg Fall(f(a))$ 与 $\neg Stock(f(a)) \vee Fall(f(a))$ 归结, 得到 $\neg Stock(f(a))$;
- 用 $\neg Fall(f(a))$ 与 $\neg Bond(f(a)) \vee Fall(f(a))$ 归结, 得到 $\neg Bond(f(a))$ 。

但前面我们已经得到

$$Stock(f(a)) \vee Bond(f(a))$$

所以这会推出矛盾。换句话说, 假设存在一个快乐投资者却没买任何黄金股, 会与前提冲突。

因此原命题成立。

小结

这类题真正的关键不是最后那几步机械归结, 而是前面三件事:

1. 自然语言翻译得对不对;
2. 目标命题否定得对不对;
3. 存在量词 Skolem 化后, 子句是否写对。

只要这三步稳住, 后面的归结过程往往就能顺出来。

第 4 题 决策树与信息增益

题意概述

给出 7 条狗的训练样本，属性为 Color、Fur、Size，类别为 dangerous 或 well-behaved。要求构造决策树，并计算每一步候选属性的信息增益。

对应知识点

这一题属于机器学习基础中的**决策树**。严格说，它不完全对应你目前主稿中某一章的主线展开，但在整门人工智能课程的机器学习部分里很常见，也很典型。

第一步：计算总体熵

7 条样本中，危险狗 3 条，温顺狗 4 条，所以总体熵为

$$H(D) = -\frac{3}{7} \log_2 \frac{3}{7} - \frac{4}{7} \log_2 \frac{4}{7} \approx 0.985$$

熵越大，表示类别越混乱；熵越小，表示越纯。

第二步：分别计算三个属性的信息增益

1. 按颜色划分 棕色有两条，且都温顺，所以

$$H(D_{brown}) = 0$$

白色有两条，一条温顺，一条危险，所以

$$H(D_{white}) = 1$$

黑色有三条，其中两条危险，一条温顺，所以

$$H(D_{black}) = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3} \approx 0.918$$

因此加权后的条件熵为

$$H(D | Color) = \frac{2}{7} \cdot 0 + \frac{2}{7} \cdot 1 + \frac{3}{7} \cdot 0.918 \approx 0.679$$

所以信息增益是

$$IG(Color) = 0.985 - 0.679 = 0.306$$

2. 按毛发类型划分 smooth 这组两条样本都危险，所以熵为 0。

curly 这组两条样本都温顺，所以熵也为 0。

ragged 这组三条样本中，两条温顺，一条危险，所以熵为

$$H(D_{ragged}) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \approx 0.918$$

于是

$$H(D | Fur) = \frac{3}{7} \cdot 0.918 + \frac{2}{7} \cdot 0 + \frac{2}{7} \cdot 0 \approx 0.393$$

所以

$$IG(Fur) = 0.985 - 0.393 = 0.592$$

说明：原题答案里写成了约 0.525，但如果按前面给出的条件熵 0.393 继续计算，正确减法应为 0.592。也就是说，这里更像是老师或 OCR 在减法结果上写错了，而不是前面熵算错了。

3. 按大小划分 small 这组有 4 条，其中 3 条温顺、1 条危险，所以

$$H(D_{small}) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \approx 0.811$$

big 这组有 3 条，其中 2 条危险、1 条温顺，所以

$$H(D_{big}) \approx 0.918$$

因此

$$H(D | Size) = \frac{4}{7} \cdot 0.811 + \frac{3}{7} \cdot 0.918 \approx 0.857$$

所以

$$IG(Size) = 0.985 - 0.857 = 0.128$$

第三步：确定根节点

三个信息增益中，Fur 最大，因此根节点应选择 Fur。

此时：

- smooth 直接判为危险；
- curly 直接判为温顺；
- ragged 这支还不纯，需要继续划分。

第四步：在 ragged 子集上继续划分

ragged 子集包含 3 条样本：

- 狗 1: brown, well-behaved

- 狗 2: black, dangerous
- 狗 7: brown, well-behaved

因此其熵为

$$H(D') = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \approx 0.918$$

若按颜色划分:

- brown 子集纯为温顺;
- black 子集纯为危险。

所以条件熵为 0, 信息增益就是

$$IG(Color) = 0.918$$

若按大小划分:

- small 只有狗 1, 纯;
- big 有狗 2 和狗 7, 一危险一温顺, 熵为 1。

所以条件熵为

$$H(D' | Size) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1 = \frac{2}{3}$$

故

$$IG(Size) = 0.918 - \frac{2}{3} \approx 0.251$$

因此第二层应该选 Color。

最终决策树

最终决策树可以写成:

- Fur = smooth : 危险
- Fur = curly : 温顺
- Fur = ragged
- 再看 Color
- Color = brown : 温顺
- Color = black : 危险

小结

这道题标准做法就是 ID3 的套路: 先算总体熵, 再算每个属性的条件熵和信息增益, 选信息增益最大的作为划分属性。只要不把样本数数错、概率写错, 整题就不难。真正要注意的是, 考试里往往会用这种题检查你是否真的会“从表格一步一步手算”, 而不是只会背结论。

第 5 题 遗传算法设计题

题意概述

需要设计遗传算法来解决“公平分宝”问题：把若干宝石分给 n 个人，使各份总价值尽量接近，也就是让不同份额之间的总价差尽量小。

对应知识点

这一题对应第六章遗传算法。重点不在复杂计算，而在于：**如何把一个实际问题翻译成遗传算法的编码、适应度、选择、交叉、变异和终止条件。**

解析

这类设计题最重要的是结构完整。只要把遗传算法的几个基本环节写全，并且每个环节都和当前问题对应起来，就能得到比较完整的答案。

首先需要想清楚**个体如何编码**。设总共有 m 件宝物，那么可以用长度为 m 的染色体表示一个划分方案。第 k 个基因取值为 $1, 2, \dots, n$ 中的某个整数，表示第 k 件宝物被分给第几个人。例如染色体

$$(1, 3, 2, 1, 2)$$

表示第 1 件和第 4 件给第 1 个人，第 3 件和第 5 件给第 2 个人，第 2 件给第 3 个人。

这样编码有一个好处：每件宝物天然只属于一个人，因此自动满足“不重叠”的要求。若进一步要求每个人至少分到一件宝物，也可以在变异或交叉后加一个修复步骤。

接着要定义**适应度函数**。原问题目标是 최소화 各份价值之间的总差：

$$\sum_{1 \leq i < j \leq n} \left| \sum_{x \in S_i} x - \sum_{y \in S_j} y \right|$$

记这个目标值为 $Cost$ ，则一个常见适应度可以定义为

$$Fitness = \frac{1}{1 + Cost}$$

或者干脆定义为 $-Cost$ 。核心思想很简单：划分越公平，总差越小，适应度越高。

之后就是遗传算法的标准流程：

1. **初始化种群**：随机生成若干条染色体，每条都表示一种宝物分配方案。
2. **计算适应度**：对每条染色体统计每个人得到的总价值，再算总差。
3. **选择**：按适应度选择较优个体进入繁殖阶段，可以用轮盘赌或锦标赛选择。
4. **交叉**：在两条父代染色体之间交换部分基因，产生新方案。例如单点交叉、两点交叉都可以。
5. **变异**：随机挑某个基因，把它改成另一个编号，表示把某件宝物改分给另一个人。
6. **形成新一代**：保留优秀个体，重复上述过程。

7. **终止条件**：达到最大代数，或若干代内最优适应度提升很小，就停止。

如果想让答案更完整，还可以补一句：为了防止最优解在进化过程中丢失，可以使用**精英保留**策略，把当前最优个体直接复制到下一代。

小结

这种题一般不要求你写具体代码，而是要求你会“把题目翻译成遗传算法语言”。考试时建议按“编码 -> 适应度 -> 初始化 -> 选择 -> 交叉 -> 变异 -> 终止”的顺序写，结构最清楚，也最不容易漏点。

第 6 题 HMM 与 Viterbi 最优路径

题意概述

给定一个三状态隐马尔可夫模型 $\lambda = (A, B, \pi)$ ，观测序列为

$$O = (red, white, white)$$

要求求出最优隐藏状态路径。

对应知识点

这一题对应第三章中的 HMM，与 PJ2 里最基础的 HMM 路线也是同一套核心思想。考点非常典型：**Viterbi 动态规划手算**。

先回忆 Viterbi 公式

若状态数为 N ，则

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(o_t)$$

其中：

- $\delta_t(j)$ 表示到时刻 t 为止、并且以状态 j 结尾的最优路径概率；
- a_{ij} 是状态转移概率；
- $b_j(o_t)$ 是在状态 j 下发出观测 o_t 的概率。

同时记录回溯指针

$$\phi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}]$$

第一步：初始化

第一个观测是 red，所以直接用初始概率乘发射概率：

$$\delta_1(1) = \pi_1 b_1(red) = 0.5 \times 0.7 = 0.35$$

$$\delta_1(2) = \pi_2 b_2(\text{red}) = 0.3 \times 0.4 = 0.12$$

$$\delta_1(3) = \pi_3 b_3(\text{red}) = 0.2 \times 0.5 = 0.10$$

初始时回溯指针记为 0 即可。

第二步：递推到 $t = 2$

第二个观测是 white。

到状态 1 的最优值：

$$\delta_2(1) = \max(0.35 \times 0.6, 0.12 \times 0.2, 0.10 \times 0.3) \times 0.3$$

先算括号内三项：

$$0.35 \times 0.6 = 0.21, \quad 0.12 \times 0.2 = 0.024, \quad 0.10 \times 0.3 = 0.03$$

最大是 0.21, 因此

$$\delta_2(1) = 0.21 \times 0.3 = 0.063, \quad \phi_2(1) = 1$$

到状态 2 的最优值：

$$\delta_2(2) = \max(0.35 \times 0.3, 0.12 \times 0.5, 0.10 \times 0.3) \times 0.6$$

括号内三项为

$$0.105, \quad 0.06, \quad 0.03$$

最大是 0.105, 所以

$$\delta_2(2) = 0.105 \times 0.6 = 0.063, \quad \phi_2(2) = 1$$

到状态 3 的最优值：

$$\delta_2(3) = \max(0.35 \times 0.1, 0.12 \times 0.3, 0.10 \times 0.4) \times 0.5$$

括号内三项为

$$0.035, \quad 0.036, \quad 0.04$$

最大是 0.04, 所以

$$\delta_2(3) = 0.04 \times 0.5 = 0.02, \quad \phi_2(3) = 3$$

第三步：递推到 $t = 3$

第三个观测仍然是 white。

到状态 1:

$$\delta_3(1) = \max(0.063 \times 0.6, 0.063 \times 0.2, 0.02 \times 0.3) \times 0.3$$

括号内为

$$0.0378, \quad 0.0126, \quad 0.006$$

故

$$\delta_3(1) = 0.0378 \times 0.3 = 0.01134, \quad \phi_3(1) = 1$$

到状态 2:

$$\delta_3(2) = \max(0.063 \times 0.3, 0.063 \times 0.5, 0.02 \times 0.3) \times 0.6$$

括号内为

$$0.0189, \quad 0.0315, \quad 0.006$$

故

$$\delta_3(2) = 0.0315 \times 0.6 = 0.0189, \quad \phi_3(2) = 2$$

到状态 3:

$$\delta_3(3) = \max(0.063 \times 0.1, 0.063 \times 0.3, 0.02 \times 0.4) \times 0.5$$

括号内为

$$0.0063, \quad 0.0189, \quad 0.008$$

故

$$\delta_3(3) = 0.0189 \times 0.5 = 0.00945, \quad \phi_3(3) = 2$$

说明：原题 md 中这里写成了 $\phi_3(3) = 3$ ，但按前面的最大值比较，真正给出最大项的是状态 2，因此更合理的回溯指针应为 2。不过这并不影响最终最优路径，因为最终最大终止状态本来就在状态 2。

第四步：终止与回溯

在最后时刻，

$$\max(\delta_3(1), \delta_3(2), \delta_3(3)) = \max(0.01134, 0.0189, 0.00945) = 0.0189$$

因此最优终止状态是 2。

回溯：

$$q_3^* = 2$$

$$q_2^* = \phi_3(2) = 2$$

$$q_1^* = \phi_2(2) = 1$$

所以最优路径是

$$(1, 2, 2)$$

小结

Viterbi 题目最重要的是别慌。每一步都只是“前一时刻最优值 $\times$ 转移概率，再乘当前发射概率”。真正容易错的地方往往是：

1. 忘了最后还要乘发射概率；
2. 把最大值和回溯指针分不清；
3. 算数出错。

因此考试时建议把每个候选值都列开，再圈出最大项。

第 7 题 神经网络综合题

题意概述

这一题分三小问：

1. 给定一个两层隐藏层的前馈网络，要求前向计算输出值，并求若干条边的梯度；
2. 给定一个图像矩阵和卷积核，求卷积结果，再求最大池化与平均池化结果，并说明池化的意义；
3. 解释批归一化与层归一化的重要性及其差别。

对应知识点

这一题对应第二章、第三章以及老师补充的神经网络部分，是很典型的“手算前向传播 + 反向传播思想 + CNN 基础 + 归一化理解”的综合题。

第一小问：前向传播与梯度

1. 先算第一层隐藏层 输入为

$$X = \begin{bmatrix} 1 \\ 0 \\ -2 \end{bmatrix}$$

第一层权重矩阵为

$$W_1 = \begin{bmatrix} 1 & 2 & -1 \\ 2 & -2 & 1 \\ -1 & 0 & 2 \end{bmatrix}$$

先算线性部分：

$$W_1 X = \begin{bmatrix} 1 & 2 & -1 \\ 2 & -2 & 1 \\ -1 & 0 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ -2 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \\ -5 \end{bmatrix}$$

ReLU 激活函数是

$$\sigma(x) = \max(0, x)$$

因此第一层隐藏层输出

$$H = \begin{bmatrix} 3 \\ 0 \\ 0 \end{bmatrix}$$

2. 再算第二层隐藏层 第二层权重矩阵

$$W_2 = \begin{bmatrix} 0 & 1 & -1 \\ 1 & 1 & -2 \end{bmatrix}$$

于是

$$W_2 H = \begin{bmatrix} 0 & 1 & -1 \\ 1 & 1 & -2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 3 \end{bmatrix}$$

经过 ReLU 后仍为

$$V = \begin{bmatrix} 0 \\ 3 \end{bmatrix}$$

3. 计算输出层 输出层权重

$$W_3 = \begin{bmatrix} 2 & -1 \end{bmatrix}$$

因此输出层线性组合为

$$W_3 V = 2 \times 0 + (-1) \times 3 = -3$$

再经过 ReLU:

$$Y = \max(0, -3) = 0$$

所以第一问第一个小问题的答案是

$$Y = 0$$

4. 求三条边的梯度 题目中:

- A 表示 $X1 \rightarrow H3$ 的权重;
- B 表示 $H3 \rightarrow V1$ 的权重;
- C 表示 $V1 \rightarrow Y$ 的权重。

先观察网络状态:

- $H3$ 的线性输入是 -5 , 经过 ReLU 后为 0 ;
- 输出层线性输入是 -3 , 经过 ReLU 后也为 0 。

只要 ReLU 输入是负数, 其导数就取 0 , 因此反向传播时梯度会被 “截断”。

损失函数为

$$L(Y, T) = \frac{1}{2}(Y - T)^2$$

目标值 $T = 1$, 所以当前损失是

$$L = \frac{1}{2}(0 - 1)^2 = \frac{1}{2}$$

但由于输出层 ReLU 的输入 $-3 < 0$, 其导数为 0 , 所以

$$\frac{\partial L}{\partial C} = 0$$

同理，通向 B 的梯度必须先经过输出层这道 ReLU，而输出层已经“死掉”，所以

$$\frac{\partial L}{\partial B} = 0$$

对于 A ，除了输出层 ReLU 导数为 0 之外， $H3$ 本身的线性输入 $-5 < 0$ ，它所在位置的 ReLU 导数也为 0，因此

$$\frac{\partial L}{\partial A} = 0$$

所以这一问最终答案是

$$\frac{\partial L}{\partial A} = 0, \quad \frac{\partial L}{\partial B} = 0, \quad \frac{\partial L}{\partial C} = 0$$

这道题的核心现象，其实就是 **dead ReLU**：一旦某个节点落在负半轴，梯度就无法继续往前传播。

第二小问：卷积与池化

输入图像矩阵为

$$\begin{bmatrix} 0 & -1 & 1 & 3 \\ 1 & 0 & 2 & 1 \\ 0 & -1 & 1 & 3 \end{bmatrix}$$

卷积核为

$$\begin{bmatrix} 1 & -1 \\ 1 & 2 \end{bmatrix}$$

步长为 1，按 CNN 中常用的做法，直接进行滑窗乘加即可。

输出大小是 2×3 。

左上角窗口

$$\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

与卷积核相乘求和：

$$0 \times 1 + (-1) \times (-1) + 1 \times 1 + 0 \times 2 = 2$$

第一行第二个窗口

$$\begin{bmatrix} -1 & 1 \\ 0 & 2 \end{bmatrix}$$

结果为

$$(-1) \times 1 + 1 \times (-1) + 0 \times 1 + 2 \times 2 = 2$$

第一行第三个窗口

$$\begin{bmatrix} 1 & 3 \\ 2 & 1 \end{bmatrix}$$

结果为

$$1 \times 1 + 3 \times (-1) + 2 \times 1 + 1 \times 2 = 2$$

第二行第一个窗口

$$\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

结果为

$$1 \times 1 + 0 \times (-1) + 0 \times 1 + (-1) \times 2 = -1$$

第二行第二个窗口

$$\begin{bmatrix} 0 & 2 \\ -1 & 1 \end{bmatrix}$$

结果为

$$0 \times 1 + 2 \times (-1) + (-1) \times 1 + 1 \times 2 = -1$$

第二行第三个窗口

$$\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

结果为

$$2 \times 1 + 1 \times (-1) + 1 \times 1 + 3 \times 2 = 8$$

因此卷积结果是

$$\begin{bmatrix} 2 & 2 & 2 \\ -1 & -1 & 8 \end{bmatrix}$$

接下来做 2×2 池化，步长为 1，所以输出是 1×2 。

第一个池化窗口为

$$\begin{bmatrix} 2 & 2 \\ -1 & -1 \end{bmatrix}$$

最大池化得到 2，平均池化得到

$$\frac{2 + 2 - 1 - 1}{4} = 0.5$$

第二个池化窗口为

$$\begin{bmatrix} 2 & 2 \\ -1 & 8 \end{bmatrix}$$

最大池化得到 8，平均池化得到

$$\frac{2 + 2 - 1 + 8}{4} = \frac{11}{4} = 2.75$$

所以：

最大池化结果为

$$\begin{bmatrix} 2 & 8 \end{bmatrix}$$

平均池化结果为

$$\begin{bmatrix} 0.5 & 2.75 \end{bmatrix}$$

池化为什么重要？可以从三个角度理解：

1. 它能降低特征图尺寸，从而减少计算量；
2. 它能保留局部区域中更有代表性的响应；
3. 它能增强模型对小幅平移、噪声扰动的鲁棒性。

第三小问：BN 与 LN

这一问是概念题。核心意思是：深层网络训练时，前面层参数的变化会不断改变后面层输入的分布，使优化变得困难。归一化的作用，就是让各层输入分布更稳定，从而：

1. 缓解内部协变量偏移；

2. 让梯度更稳定;
3. 允许使用更大的学习率;
4. 加快收敛速度;
5. 在一定程度上带来正则化效果。

批归一化 (Batch Normalization, BN) 是在一个 batch 内, 对同一特征维度 across samples 做归一化。因此它依赖 batch 统计量, 对 batch 大小比较敏感, 在卷积网络里很常见。

层归一化 (Layer Normalization, LN) 则是对单个样本内部 across features 做归一化。它不依赖 batch 大小, 因此在序列模型、Transformer 等场景里更自然。

一句话概括:

- BN: 同一特征, 看一批样本;
- LN: 同一样本, 看一层特征。

小结

这一大题非常像真正考试中的“重计算综合题”。做的时候最重要的是: 前向传播一层一层算, 不要跳; 卷积窗口一个一个滑, 不要心算; 遇到 ReLU 梯度时, 一定先判断输入是正还是负。

第 8 题 单个 sigmoid 单元与 L_2 正则化

题意概述

给定误差函数

$$E(w) = \frac{1}{2} \sum_n (y(x^{(n)}, w) - t^{(n)})^2 + \frac{1}{2} \beta \sum_j w_j^2$$

其中输出单元是 sigmoid, 要求:

1. 求 $\frac{\partial E}{\partial w_j}$;
2. 写出单个训练样本下的梯度下降更新式;
3. 判断两张 sigmoid 图中哪一张对应更大的 $\|w\|^2$;
4. 说明为什么惩罚大权重有意义, 以及怎样选择 β 。

对应知识点

这一题对应第二章、第三章里神经网络、梯度下降与正则化的内容。虽然形式上是一个单神经元, 但它已经把链式法则、sigmoid 导数和 L_2 正则化放在一起考了。

第一问: 求偏导

先把训练样本编号写清楚, 避免把样本下标和权重下标混淆。对第 n 个样本, 有

$$y^{(n)} = y(x^{(n)}, w)$$

sigmoid 函数满足

$$s'(z) = s(z)(1 - s(z))$$

因此平方误差项对 w_j 的导数是

$$\sum_n (y^{(n)} - t^{(n)}) y^{(n)} (1 - y^{(n)}) x_j^{(n)}$$

正则项

$$\frac{1}{2} \beta \sum_j w_j^2$$

对 w_j 的导数则是

$$\beta w_j$$

所以总导数为

$$\frac{\partial E}{\partial w_j} = \sum_n (y^{(n)} - t^{(n)}) y^{(n)} (1 - y^{(n)}) x_j^{(n)} + \beta w_j$$

原题答案里把样本指标和权重指标都写成了 j ，意思是对的，但记号略有混乱。考试时自己写时，最好像上面这样把样本编号和权重编号分开。

第二问：单样本更新

若只用一个训练样本 (x, y^*) 做梯度下降，学习率为 η ，则更新式就是

$$w_j \leftarrow w_j - \eta [(y - y^*) y (1 - y) x_j + \beta w_j]$$

前半部分来自数据误差，后半部分来自正则惩罚。

第三问：哪张图对应更大的权重模长

sigmoid 函数是一条 S 形曲线。权重向量模长越大，也就是 $\|w\|^2$ 越大，意味着输入线性组合变化时，输出曲线会变化得更陡。换句话说，决策边界附近的过渡会更“突然”。

因此，**更陡峭的那张图对应更大的 $\|w\|^2$** 。原题答案给的是 Graph B，对应的理解就是：B 的变化更陡，所以它的权重模更大。

第四问：为什么要惩罚大权重

惩罚大权重至少有两个重要理由。

第一，它能**抑制过拟合**。如果权重过大，模型会为了贴合训练样本而形成过于陡峭、过于敏感的决策边界，泛化能力往往变差。

第二，它能**缓解 sigmoid 饱和问题**。当线性输入绝对值很大时，sigmoid 会进入饱和区，导数接近 0，梯度下降就会变慢。限制权重规模，能在一定程度上避免过早进入严重饱和区域。

至于 β 的选择，最常见做法是：

1. 先取若干候选值；
2. 用验证集或交叉验证分别训练、评估；
3. 选验证表现最好的那个。

也就是说， β 不是靠拍脑袋定的，而是靠验证过程挑出来的。

小结

这道题把“链式法则 + sigmoid 导数 + 正则化”三件事揉在一起了。若把这三件事分别想清楚，题目并不复杂。最关键的是记住：

$$s'(z) = s(z)(1 - s(z))$$

以及

$$\frac{\partial}{\partial w_j} \frac{1}{2} \beta w_j^2 = \beta w_j$$

前者是激活函数带来的梯度，后者是正则项带来的梯度。

总结

从这份真题的风格可以很明显地看出几个特点。第一，题目覆盖范围很广，从模糊逻辑、规则系统、逻辑推理、决策树、遗传算法，到 HMM、神经网络、正则化都有涉及。第二，很多题并不是单纯记忆题，而是要求把概念真正落实到书写、推导和手算上。第三，逻辑、概率模型和神经网络这三类内容的计算感都很强，做题时必须步骤清楚，不能只写最后结论。

如果把这份真题当作复习样本，那么最值得反复练的，至少包括以下几类能力：把自然语言翻成逻辑公式；把一阶逻辑进一步化成子句并做归结；熟练手算信息熵与信息增益；熟练写出遗传算法设计框架；熟练使用 Viterbi 算法；会做前向传播、卷积和简单反向传播；理解 BN、LN、正则化等神经网络概念背后的真实作用。只要这些能力练扎实，再去考其他模拟题时，心里就会稳很多。