

我是人工智能

GYF

2026 年春

目录

人工智能 (H) 复习提要	2
使用说明	2
1. 为什么写这份资料	2
2. 写作约定与版权申明	2
1 人工智能概述 (Introduction)	2
一、本章概述	2
二、知识点讲解	2
1.1 人工智能的研究对象与基本目标	2
1.2 两条经典技术路线：符号主义与连接主义	3
1.3 String manipulation 与形式化推理的直觉	3
1.4 AI 研究方法的基本框架	3
三、复习与巩固	4
题目 1	4
题目 2	4
参考答案	4
2 连接主义，从线性到神经 (Connectionist, Linear-to-neural)	4
一、本章概述	4
二、知识点讲解	4
2.1 从线性模型到神经元模型	4
2.2 感知机与其局限	5
2.3 Sigmoid、可导性与梯度下降	5
2.4 均方误差与偏导数的意义	6
2.5 反向传播：输出层到隐藏层	6
2.6 线性代数视角：矩阵化表达为什么必要	7
2.7 无监督竞争学习：Winner-Take-All (WTA)	7

三、复习与巩固	7
题目 1	7
题目 2	8
题目 3	8
参考答案	8

人工智能 (H) 复习提要

复旦大学人工智能 (H) 课程复习提要。

制作者：GYF

授课老师：郑晓庆

使用说明

1. 为什么写这份资料

课程 PPT 信息密度高、以英文为主、图较多而文字较精炼，平时听课时问题不大，但复习和开卷查找时不够顺手。本讲义的目标是把核心概念改写成中文、按逻辑串起来，便于初学者或水平较逊者（如 GYF）理解。

2. 写作约定与版权申明

1. 主要讲解形式化定义、考试高频公式和推导关键步骤，对于一些更深层的内容，由于制作者水平较逊，本材料难以支撑。望理解，谢谢！
2. 本资料版权归复旦大学计算机专业的 GYF 所有。资料公开后，可进行下载、阅读，也欢迎交流讨论其中的不当之处。但请不要擅自删改、售卖，或用于其他不合适的途径。谢谢！

1 人工智能概述 (Introduction)

一、本章概述

这一章的作用，是先把“人工智能到底在研究什么”讲清楚。它不是某一个单独算法，而是一整套让机器具备感知、学习、推理和决策能力的方法体系。后续会同时学习机器学习、深度学习、知识表示、逻辑推理和搜索。第一章的意义，就是先建立共同语言：哪些问题属于 AI，AI 方法为什么既有“数据驱动”一派，也有“逻辑推理”一派。

二、知识点讲解

1.1 人工智能的研究对象与基本目标

人工智能 (Artificial Intelligence, AI) 通常可理解为：研究如何构造计算系统，使其完成通常需要人类智能才能完成的任务。

这里的“智能任务”主要包括：

1. 感知：识别图像、语音、文本中的有效信息。
2. 学习：从数据中总结规律，而不是完全手写规则。
3. 推理：根据已知事实得出结论。
4. 规划与决策：在目标约束下选择动作序列。

学习时容易出现一个误区：把 AI 等同于深度学习。实际上，深度学习是 AI 的重要分支，但并不覆盖全部内容。后续课程里的知识表示、符号推理、搜索策略、专家系统，同样是 AI 核心组成。

1.2 两条经典技术路线：符号主义与连接主义

第一章里会反复出现逻辑学与数学史人物（如 Aristotle、Boole、Frege、Turing 等），目的不是考历史细节，而是说明 AI 的两条源头。

第一条是符号主义路线。它强调：

1. 用明确的符号结构表示知识（如命题、谓词、规则）。
2. 用逻辑演算把已有知识转化为新结论。

第二条是连接主义路线。它强调：

1. 用参数化模型（如神经网络）从数据中自动学习表示。
2. 通过优化目标函数不断更新参数。

在现代 AI 系统中，这两条路线往往不是完全对立，而是可以互补。比如大模型在学习表示方面很强，但在严格逻辑约束、可验证推理、知识结构化表达方面，仍常要借助符号方法。

1.3 String manipulation 与形式化推理的直觉

01Introduction 里有一部分“String manipulation（符号串操作）”，提到例如“person has fever”“take aspirin”这类规则表达。尽管 PPT 图示里有些箭头和符号在提取后不完整，但核心思想很清楚：

1. 把知识写成可操作的符号串。
2. 按规则把一串符号变成另一串符号。
3. 推理过程可被看作“符号变换序列”。

这件事在数学上对应形式系统（formal system）：

1. 有语法对象（字符串/公式）。
2. 有变换规则（推理规则）。
3. 有可验证的推导过程。

它的重要性在于：后续一阶谓词逻辑、归结推理、专家系统，都依赖这个思想。

1.4 AI 研究方法的基本框架

从第一章视角看，AI 问题通常可被拆成三层：

1. 表示层：如何表示输入、状态、知识、目标。
2. 模型层：用什么模型学习或推理（线性模型、神经网络、图模型、逻辑系统等）。
3. 求解层：如何训练或搜索（梯度下降、动态规划、启发式搜索等）。

这三层对应你后续复习时的一个实用习惯：读任何新方法，都先问“表示是什么、目标函数是什么、优化或推理怎么做”。这样不容易被零散术语打乱。

三、复习与巩固

题目 1

请简要说明为什么“AI 不等于深度学习”。要求至少给出两个理由。

题目 2

在“符号串操作”的视角下，解释为什么逻辑推理可以被程序化实现。

参考答案

1. AI 不等于深度学习，至少有两点：第一，AI 还包含知识表示、逻辑推理、搜索、专家系统等传统核心内容；第二，很多任务需要可解释规则或严格约束，仅靠深度模型不一定稳定满足，因此常需符号方法配合。
2. 因为推理可以形式化为“符号串到符号串”的规则变换：先定义表达形式，再定义合法变换规则，最后按规则逐步推出结论。只要规则可形式化，程序就可按固定步骤执行。

2 连接主义，从线性到神经（Connectionist, Linear-to-neural）

一、本章概述

这一章主要回答一个问题：为什么要从线性模型走向神经网络，再走向多层网络。课程中通过感知机、Sigmoid、梯度下降、反向传播等内容，逐步建立“模型-损失-优化”这条主线。

同时，老师补充的 Linear-to-neural 部分很关键，它把“线性回归的最小二乘目标”和“神经网络的损失最小化”连在一起。理解这条过渡线，后面学深度学习会轻松很多。

二、知识点讲解

2.1 从线性模型到神经元模型

最基本的线性模型可写为

$$\hat{y} = w^T x + b.$$

在线性回归里，常用残差平方和（RSS）作为目标：

$$\text{RSS}(w, b) = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Linear-to-neural 里出现的 $f(x, w)$ 、 $\nabla \text{RSS}(w)$ ，本质上对应“模型输出”和“目标函数梯度”。梯度告诉我们：参数往哪个方向改，损失下降最快。

神经元模型在形式上与线性模型非常接近，只是在线性组合后加了激活函数：

$$z = \sum_i w_i x_i + b, \quad o = f(z).$$

激活函数的作用是引入非线性。没有非线性，多层线性叠加仍等价于一层线性模型，表示能力不会真正提升。

2.2 感知机与其局限

感知机可写成阈值判别形式：

$$o = \text{sign} \left(\sum_i w_i x_i - t \right),$$

其中 t 是阈值。训练时常用“预测错才更新”的规则。按课件记号，可写为

$$\Delta w_i = r(d - \text{sign}(\sum_j w_j x_j))x_i,$$

这里 r 是学习率， d 是目标标记。

PPT 里专门展示了 XOR 例子。它的关键结论是：单层感知机只能学线性可分问题，而 XOR 是非线性可分，因此无法用单层感知机正确分类。这正是“为什么要引入隐藏层”的核心动机之一。

2.3 Sigmoid、可导性与梯度下降

硬阈值函数不光滑，几乎处处不可导，不利于用梯度法优化。于是引入 Sigmoid：

$$f(\sigma) = \frac{1}{1 + e^{-\sigma}},$$

其导数有简洁形式：

$$f'(\sigma) = f(\sigma)(1 - f(\sigma)).$$

这条导数公式非常重要，因为反向传播里反复要用到。

梯度下降的基本更新是

$$\theta \leftarrow \theta - \eta \nabla L(\theta),$$

其中 η 为学习率， $L(\theta)$ 为损失函数。Linear-to-neural 里关于 $L(\theta + \Delta\theta)$ 的泰勒展开，本质是解释为什么沿负梯度方向更新通常会让损失下降。

2.4 均方误差与偏导数的意义

课件里的均方误差可写为

$$E = \frac{1}{2} \sum_i (d_i - o_i)^2.$$

很多同学第一次看偏导会觉得抽象。这里可以把偏导理解成“当只微调某一个参数时，损失变化有多敏感”。如果

$$\frac{\partial E}{\partial w}$$

绝对值很大，说明这个参数当前位置对损失影响很强；若接近 0，说明局部上影响较弱。

在神经网络里参数很多，不可能手工逐个试，所以用偏数组成的梯度向量统一更新，是高维优化的自然做法。

2.5 反向传播：输出层到隐藏层

反向传播 (Backpropagation) 是“链式法则在网络上的系统化应用”。

对输出层权重，典型更新形式为

$$\Delta w_{ji} = \eta (d_i - o_i) o_i (1 - o_i) o_j,$$

其中 o_j 是隐藏层节点输出。

对隐藏层权重，梯度需要再乘以后续层误差信号，形成“误差反传”结构。课件中对应形式可写为

$$\Delta w_{kj} = \eta o_j (1 - o_j) o_k \sum_i w_{ji} o_i (1 - o_i) (d_i - o_i).$$

不必死记所有下标，先抓住两点：

1. 每层的更新都由“本层输入”与“本层误差信号”共同决定。
2. 隐藏层误差信号来自后层误差经权重加权回传。

这两点理解透了，公式推导就有了主线。

2.6 线性代数视角：矩阵化表达为什么必要

Linear-to-neural 中提到的 Φ 、 $F = HY$ 等写法，本质是把样本和参数写成矩阵形式，便于统一计算与实现。

例如，线性回归常写成

$$\hat{y} = \Phi w,$$

其中 Φ 是设计矩阵（每行一个样本特征）。这样一来，预测、损失、梯度都可以矩阵化表示，更适合实现批量计算，也更清楚地揭示了模型结构。

对神经网络同理：单样本的标量公式看起来直观，但工程实现和复杂度分析通常依赖矩阵形式。

2.7 无监督竞争学习：Winner-Take-All (WTA)

02Connectionist 后半部分介绍了竞争学习。核心想法是：给定输入向量 X ，先找“距离最近”的原型向量（赢家），只更新赢家参数。

常用欧氏距离：

$$\|X - W\|^2 = \sum_i (x_i - w_i)^2.$$

赢家权重更新可写成

$$W^{(t)} = W^{(t-1)} + c(X^{(t)} - W^{(t-1)}),$$

其效果是把原型向量拉向当前样本。长期迭代后，不同原型会对应不同数据簇，形成无监督分类的基础。

三、复习与巩固

题目 1

设单个神经元输出为 $o = f(z)$ ， $z = w_1 x_1 + w_2 x_2 + b$ ，其中 f 为 Sigmoid。请回答：

1. 为什么引入 Sigmoid 后可以使用梯度下降？
2. 写出 $f'(z)$ 的表达式。

题目 2

给定样本点 (x_1, x_2) 与标签如下: $(1, 1) \rightarrow 0$, $(1, 0) \rightarrow 1$, $(0, 1) \rightarrow 1$, $(0, 0) \rightarrow 0$ 。请判断该问题是否可由单层感知机完全正确分类, 并说明理由。

题目 3

在 Winner-Take-All 中, 若当前赢家原型向量为 $W = (2, 9)$, 学习率 $c = 0.5$, 当前输入 $X = (1, 1)$, 请计算更新后的 W' 。

参考答案

1. Sigmoid 是连续可导函数, 损失函数对参数可求偏导, 因此可以沿负梯度方向迭代更新参数; 其导数是 $f'(z) = f(z)(1 - f(z))$ 。
2. 不能。该数据对应 XOR 模式, 属于线性不可分问题, 单层感知机只能表示线性可分边界, 因此无法同时满足四个样本点的分类要求。
3. 代入更新式:

$$W' = W + c(X - W) = (2, 9) + 0.5((1, 1) - (2, 9)) = (2, 9) + 0.5(-1, -8) = (1.5, 5).$$