

我是概统

茆诗松《概率论与数理统计教程》复习提要。

制作者: GYF

GitHub: <https://github.com/23300240002>

第一章 随机事件与概率

1.1 随机事件及其运算

主要内容: 随机现象, 样本空间, 随机事件, 事件间的关系与运算, 事件域。

- 知识点:
 - 样本空间与事件: 样本空间 Ω 是一次试验所有可能结果的集合; 事件是 Ω 的子集, 用集合来描述“哪些结果属于该事件”。
 - 相容/互不相容: 两个事件能同时发生则相容; 若交集为空 (不能同时发生) 则互不相容。
 - 对立事件: A 的对立事件是 $\bar{A}$, 必有且仅有一个发生, 且 $A \cup \bar{A} = \Omega$, $A \cap \bar{A} = \emptyset$ 。
 - 事件运算与直观: 并、交、差、补在韦恩图上有直接图形含义, 帮助区分“至少一个”“同时发生”“只发生其一”。
 - 事件域: 对并、交、补都闭合的事件集合族; 保证我们在这个“封闭的宇宙”里讨论事件, 不会因为运算跳出定义范围。
 - 概率公理 (Kolmogorov): (1) 非负性 $P(A) \geq 0$; (2) 规范性 $P(\Omega) = 1$; (3) 可列可加性: 互不相容事件列 A_i 满足 $P(\bigcup A_i) = \sum_i P(A_i)$ 。
- 典型例题:
 - ★☆☆☆☆ 写出连续抛一枚硬币, 直至出现正面为止的样本空间。
 - * 解答: 样本空间为 $\{H, TH, TTH, TTTH, \dots\}$, 第 k 个样本对应前 $k-1$ 次为反面 T , 第 k 次为正面 H 。
 - ★☆☆☆☆ 证明 $A = AB \cup A\bar{B}$ 。
 - * 解答: 全集 Ω 可以拆成 $B \cup \bar{B}$ 。把 A 看作 $A \cap \Omega$, 代入 $\Omega = B \cup \bar{B}$ 得 $A = A \cap (B \cup \bar{B}) = (A \cap B) \cup (A \cap \bar{B})$ 。

1.2 概率的定义及其确定方法

主要内容: 概率的公理化定义, 频率法、古典法、几何法、主观法。

- 知识点:
 - 古典概型: 有限且等可能的结果, 概率等于“有利结果数/全部结果数”。“等可能”就是每个基本结果的权重相同。
 - 几何概型: 在长度/面积/体积可度量的连续空间, 概率用“测度比”表示: $P(A) = \frac{\text{测度}(A)}{\text{测度}(\Omega)}$ 。等密度假设 = 在可行区域内落点均匀分布。
 - 频率法: 大量重复试验的相对频率趋向稳定数, 此稳定数被视为概率; 强调“实验可验证”的直觉。
 - 主观概率: 基于个人或专家的信念/信息并可随新信息更新, 可用贝叶斯方法调整。
- 典型例题:
 - ★★☆☆☆ 六根草随机成对相接, 求恰成一个环的概率 (答案 $8/15$)。
 - * 思路: 共有 $(6-1)!! = 5 \cdot 3 \cdot 1 = 15$ 种无标号成对连接方式 (“握手配对”模型)。要形成一个环, 需要避免产生小环; 对 6 段有 8 种连成单环的方式, 可直接枚举: 任取一端, 有 5 种连接对象; 若接成邻端, 剩 4 端必须封成一环 (2 种); 若接到非邻端, 剩 4 端先连成两条链再封口 (6 种), 合计 8, 故 $P = 8/15$ 。
 - ★★★☆☆ 将 n 个相同球随机放入 N 个盒子。
 - 1) 某指定盒中恰有 k 个球的概率: 等价于给其余 $N-1$ 盒分 $n-k$ 球; 方式数 $C_{n-k+N-2}^{N-2}$, 总方式 C_{n+N-1}^{N-1} , 故 $P = \frac{C_{n-k+N-2}^{N-2}}{C_{n+N-1}^{N-1}}$ 。
 - 2) 恰有 m 个空盒: 先选空盒 C_N^m ; 余 $N-m$ 盒全非空, 等价于求正整数解个数 $x_1 + \dots + x_{N-m} = n$, 用隔板法先每盒放 1 个, 剩 $n - (N-m)$ 球自由分配, 方式 C_{n-1}^{N-m-1} , 故 $P = \frac{C_N^m C_{n-1}^{N-m-1}}{C_{n+N-1}^{N-1}}$ 。

3) 某指定的 m 盒中恰好有 j 个球: 把 j 球分给这 m 盒 (可空), 方式 C_{j+m-1}^{m-1} ; 其余 $n-j$ 球分到 $N-m$ 盒, 方式 $C_{n-j+N-m-1}^{N-m-1}$; 总方式 C_{n+N-1}^{N-1} , 故 $P = \frac{C_{j+m-1}^{m-1} C_{n-j+N-m-1}^{N-m-1}}{C_{n+N-1}^{N-1}}$ 。

1.3 概率的性质

主要内容: 概率的可加性、单调性、加法公式、连续性。

• 知识点:

- 单调性: 若 $A \subseteq B$, 则 $P(A) \leq P(B)$ 。
- 加法公式: 任意事件 A, B , $P(A \cup B) = P(A) + P(B) - P(A \cap B)$; 推广到有限多个事件的容斥原理。
- 连续性: 若 $A_n \uparrow A$, 则 $P(A_n) \uparrow P(A)$; 若 $A_n \downarrow A$, 则 $P(A_n) \downarrow P(A)$ 。($A_n \uparrow A$ 表示事件序列单调递增且并集极限为 A ; $A_n \downarrow A$ 表示单调递减且交集极限为 A 。)

• 典型例题:

- ★★★★★ 夜间取枪问题: n 人随机取 n 枝枪, 求至少一人取到自己的枪的概率。
 - * 递推法: 全错排数 D_n 满足 $D_n = (n-1)(D_{n-1} + D_{n-2})$, 且 $D_1 = 0, D_2 = 1$, 解得 $D_n \approx n!/e$, 故 $P(\text{至少一人对}) = 1 - D_n/n!$ 。
 - * 直接用加法公式/容斥 (不借助递推): 设 A_i 表示第 i 个人取对。则 $P(\text{至少一人对}) = \sum P(A_i) - \sum P(A_i \cap A_j) + \dots + (-1)^{k+1} \sum P(A_{i_1} \cap \dots \cap A_{i_k}) + \dots$ 。任取 k 人取对, 余 $(n-k)$ 枝枪与 $(n-k)$ 人错排, 其概率是 $\frac{(n-k)!}{n!}$ 。因此

$$P(\text{至少一人对}) = \sum_{k=1}^n (-1)^{k+1} C_n^k \frac{(n-k)!}{n!} = 1 - \sum_{k=0}^n \frac{(-1)^k}{k!},$$

极限趋近 $1 - 1/e \approx 0.632$, 与递推法一致。

- ★★★★★ 证明 $|P(A \cap B) - P(A)P(B)| \leq \frac{1}{4}$ 。
 - * 设 $p = P(A)$, $q = P(B)$, 不妨令 $p \geq q$ 。上界: $P(A \cap B) - pq \leq P(B) - pq = q(1-p)$, 在 $p \geq q$, $q \in [0, 1]$ 时最大值出现在 $p = q = \frac{1}{2}$, 为 $\frac{1}{4}$ 。
 - * 下界看 $P(A)P(B) - P(A \cap B)$ 。分解

$$pq - P(A \cap B) = pP(\bar{A} \cap B) + P(A \cap B)(p-1).$$

第二项非正, 第一项 $\leq pP(\bar{A} \cap B) \leq pP(\bar{A}) = p(1-p)$, 其最大值在 $p = \frac{1}{2}$ 为 $\frac{1}{4}$ 。综合两端, 绝对值界均不超过 $1/4$, 对称性成立。

1.4 条件概率

主要内容: 条件概率定义, 乘法公式, 全概率公式, 贝叶斯公式。

• 知识点:

- 条件概率: $P(A | B) = \frac{P(A \cap B)}{P(B)}$, 表示“在 B 已发生”这一信息下 A 的可能性; 因分母 $P(B)$ 必须非零。
- 乘法公式: $P(A \cap B) = P(B)P(A | B) = P(A)P(B | A)$, 把“同时发生”拆成“先发生一件, 再在此条件下发生另一件”。
- 完备事件组与全概率: 若 $\{B_i\}$ 两两互不相容且并集为 Ω (完备事件组), 则 $P(A) = \sum_i P(B_i)P(A | B_i)$, 即先分类讨论 B_i , 再加总。
- 贝叶斯公式: $P(B_j | A) = \frac{P(B_j)P(A | B_j)}{\sum_i P(B_i)P(A | B_i)}$, 含义是“先验 $P(B_j)$ 结合证据 A 的似然 $P(A | B_j)$, 得到更新后的后验概率”。是信息更新的数学刻画。

• 典型例题:

- ★★★★★ 色盲与性别: 男女比例 22 : 21, 男色盲率 5%, 女色盲率 0.25%, 抽到色盲者求为男性的概率。
 - * 设事件 M 为男性, C 为色盲。 $P(M) = \frac{22}{43}$, $P(\bar{M}) = \frac{21}{43}$; $P(C | M) = 0.05$, $P(C | \bar{M}) = 0.0025$ 。

- * 全概率得 $P(C) = P(M)P(C|M) + P(\bar{M})P(C|\bar{M}) = \frac{22}{43} \cdot 0.05 + \frac{21}{43} \cdot 0.0025 \approx 0.0258$ 。
- * 贝叶斯: $P(M|C) = \frac{0.05 \cdot 22/43}{0.0258} \approx 0.9545$ 。

1.5 独立性

主要内容: 两个事件独立, 多事件相互独立, 试验独立。

- 知识点:
 - 两事件独立: $P(A \cap B) = P(A)P(B)$ 。
 - 三事件相互独立需同时满足两两独立与三者联合独立: $P(A \cap B \cap C) = P(A)P(B)P(C)$ 。
 - 独立与互斥不同: 互斥非零概率事件不独立。
 - 独立性在乘法公式和分解计算中的常用性: 独立则 $P(A|B) = P(A)$ 。
- 典型例题:
 - ★★★☆☆ 设 A, B, C 两两独立且 $A \cap B \cap C = \emptyset$ 。
 - 1) 若 $P(A) = P(B) = P(C) = x$, 求使 $P(A \cup B \cup C)$ 最大的 x 。
 - 2) 若 $P(A) = P(B) = P(C) < 1/2$ 且 $P(A \cup B \cup C) = 9/16$, 求 $P(A)$ 。
 - * 解答: 两两独立给出 $P(A \cap B) = x^2$ 等。因 $A \cap B \cap C = \emptyset$, 由加法公式

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) = 3x - 3x^2.$$

- 1) 求最大值: 看作一元二次函数 $f(x) = 3x - 3x^2$, 顶点在 $x = \frac{1}{2}$, 值 $f(1/2) = \frac{3}{4}$, 故最大时 $x = 0.5$ 。
- 2) 已知 $3x - 3x^2 = \frac{9}{16}$, 化为 $3x^2 - 3x + \frac{9}{16} = 0$, 即 $48x^2 - 48x + 9 = 0$, 解得 $x = \frac{1}{4}$ (另一根大于 $1/2$ 不合题设), 故 $P(A) = \frac{1}{4}$ 。

第二章 随机变量及其分布

2.1 随机变量及其分布

主要内容: 随机变量定义, 分布函数, 离散型分布列, 连续型密度函数。

- 知识点:
 - 随机变量: 把样本空间的结果用实数描述的函数 (数值刻画结果)。
 - 分布函数 $F_X(x)$: $P(X \leq x)$, 单调右连续, $\lim_{x \rightarrow -\infty} F = 0$, $\lim_{x \rightarrow +\infty} F = 1$ 。
 - 离散型: $P(X = x_k) = p_k$, 分布列 $\{(x_k, p_k)\}$, $\sum p_k = 1$, F 为阶梯状。
 - 连续型: 存在密度 $f(x)$, $f \geq 0$, $\int f = 1$, $F(x) = \int_{-\infty}^x f(t) dt$, 单点概率为 0。

2.2 随机变量的数学期望

主要内容: 数学期望定义、线性性质、常用性质。

- 知识点:
 - 定义: 离散型 $E(X) = \sum x_k p_k$; 连续型 $E(X) = \int x f(x) dx$ (绝对可积保证收敛)。
 - 线性: $E(aX + bY) = aE(X) + bE(Y)$; 常数项直接取值。
 - 单调/正性: 若 $X \geq 0$ 则 $E(X) \geq 0$; 若 $X \leq Y$ 则 $E(X) \leq E(Y)$ (在期望存在时)。
 - 受控收敛: 若 $|X| \leq M$, 则 $|E(X)| \leq M$ 。
- 典型例题:
 - ★★★☆☆ 检查抽检次数的期望。一次检测产品, 若前 a 件都合格则判定合格; 若在前 a 件内发现不合格即停并判定不合格。每件独立, 出现不合格的概率为 p 。
 - * 设第 k 件是首个不合格 ($1 \leq k \leq a$), 概率 $(1-p)^{k-1}p$, 此时检测件数为 k 。若前 a 件全合格, 概率 $(1-p)^a$, 检测件数为 a 。因此期望

$$E(N) = \sum_{k=1}^a k(1-p)^{k-1}p + a(1-p)^a.$$

- * 拆和: $\sum_{k=1}^a k(1-p)^{k-1}p$ 是截断的几何期望。用等比求和: 先记 $S = \sum_{k=1}^a kr^{k-1}$, $r = 1-p$ 。
推法: 先有 $\sum_{k=0}^a r^k = \frac{1-r^{a+1}}{1-r}$, 对 r 求导得 $\sum_{k=1}^a kr^{k-1} = \frac{1-ar^{a-1}+(a-1)r^a}{(1-r)^2}$ (把导数两边展开并整理即可)。代入得

$$E(N) = p \frac{1-ar^{a-1}+(a-1)r^a}{(1-r)^2} + ar^a, \quad r = 1-p.$$

- * 化简: $(1-r) = p$, 整理得到 $E(N) = \frac{1-(1-p)^a}{p}$ 。
- ★★★★★ 证明 $E(X) = \int_0^\infty [1-F(x)]dx - \int_{-\infty}^0 F(x)dx$ (假设期望存在)。
- * 把期望拆成正负部分: $E(X) = \int_0^\infty xf(x)dx + \int_{-\infty}^0 xf(x)dx$ 。
- * 对正半轴, 写成二重积分: $x = \int_0^x 1dy$, 故

$$\int_0^\infty xf(x)dx = \int_0^\infty \int_0^x 1 \cdot f(x)dydx.$$

交换次序 (Fubini, 非负可行): y 先行, x 从 y 到 ∞ , 得

$$\int_0^\infty \left[\int_y^\infty f(x)dx \right] dy = \int_0^\infty [1-F(y)]dy.$$

- * 对负半轴, 写 $x = -\int_x^0 1dy$, 得

$$\int_{-\infty}^0 xf(x)dx = -\int_{-\infty}^0 \int_x^0 1 \cdot f(x)dydx.$$

换序: y 从 $-\infty$ 到 0 , x 从 $-\infty$ 到 y , 得到

$$-\int_{-\infty}^0 \left[\int_{-\infty}^y f(x)dx \right] dy = -\int_{-\infty}^0 F(y)dy.$$

- * 两部分相加即得所求公式。

2.3 随机变量的方差与标准差

主要内容: 方差与标准差定义, 性质, 切比雪夫不等式。

- 知识点:
 - 方差: $\text{Var}(X) = E[(X-E(X))^2] = E(X^2) - (E(X))^2$; 标准差为方差的平方根。
 - 性质: 对常数 c , $\text{Var}(c) = 0$; 对 a, b , $\text{Var}(aX+b) = a^2 \text{Var}(X)$; 独立时 $\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y)$ 。
 - 切比雪夫不等式: 对任意 $\varepsilon > 0$, $P(|X-E(X)| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$, 刻画“离均值偏离的概率”上界。
- 典型例题:
 - ★★★★★☆ 设 $X \geq 0$, $a > 0$, 若 $E(e^{aX})$ 存在, 证明对任意 $x > 0$ 有 $P(X \geq x) \leq \frac{E(e^{aX})}{e^{ax}}$ 。
 - * 思路: 对任意单调非减且非负的 g , 都有 $P(X \geq x) \leq \frac{E[g(X)]}{g(x)}$ 。选 $g(t) = e^{at}$ 即得结论。
 - * 推导 (两次“放大”):
 - 1) $P(X \geq x) = \int_x^\infty p_X(t)dt \leq \int_x^\infty \frac{g(t)}{g(x)} p_X(t)dt$, 因为 $g(t) \geq g(x)$ 当 $t \geq x$ 。
 - 2) 再把积分区间从 $[x, \infty)$ 放大到全轴: $\int_x^\infty \frac{g(t)}{g(x)} p_X(t)dt \leq \int_{-\infty}^\infty \frac{g(t)}{g(x)} p_X(t)dt = \frac{E[g(X)]}{g(x)}$ 。
 - 3) 代入 $g(t) = e^{at}$, 得到 $P(X \geq x) \leq \frac{E(e^{aX})}{e^{ax}}$ 。

2.4 常用离散分布

主要内容：二项、泊松、超几何、几何与负二项分布的表达、期望方差、常用性质。

• 知识点（熟练背诵）：

- 二项 $X \sim b(n, p)$: $P(X = k) = C_n^k p^k (1-p)^{n-k}$; $E(X) = np$, $\text{Var}(X) = np(1-p)$ 。含义： n 次独立伯努利试验中的成功次数，如“做 n 道是非题答对几道”。
- 泊松 $X \sim P(\lambda)$: $P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$, $k = 0, 1, \dots$; $E(X) = \lambda$, $\text{Var}(X) = \lambda$ 。含义：固定时间/区域内的稀有事件计数，如“每小时来店顾客数”“芯片缺陷点数”。
- 超几何 $X \sim h(n, N, M)$: $P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$, $E(X) = n \frac{M}{N}$, $\text{Var}(X) = n \frac{M}{N} (1 - \frac{M}{N}) \frac{N-n}{N-1}$ 。含义：不放回抽样的成功个数，如“从 N 件货中含 M 件次品，抽 n 件抽到多少次品”。
- 几何 $X \sim \text{Ge}(p)$: $P(X = k) = (1-p)^{k-1} p$, $E(X) = \frac{1}{p}$, $\text{Var}(X) = \frac{1-p}{p^2}$ 。含义：首次成功出现的试验次序，如“第几次投篮命中”。
- 负二项 $X \sim \text{Nb}(r, p)$: $P(X = k) = C_{k-1}^{r-1} p^r (1-p)^{k-r}$, $k = r, r+1, \dots$; $E(X) = \frac{r}{p}$, $\text{Var}(X) = \frac{r(1-p)}{p^2}$ 。含义：达到第 r 次成功所需的总试验次数，如“集齐 r 次命中要投多少次”。

• 典型例题：

- ★☆☆☆☆ $X \sim \text{Pois}(\lambda)$ 且 $P(X = 1) = P(X = 2)$ ，求 $P(X = 4)$ 。
* $e^{-\lambda} \lambda^1 / 1! = e^{-\lambda} \lambda^2 / 2!$ 得 $\lambda = 2$ 。故 $P(X = 4) = e^{-2} \frac{2^4}{4!} = \frac{2}{3} e^{-2}$ 。
- ★★☆☆☆ 药物有效性的贝叶斯计算：一年感冒次数若药有效则 $\lambda = 3$ ，无效则 $\lambda = 5$ 。药物对人群有效概率 0.75。某人服药后一年感冒 2 次，求药对其有效的后验概率。
* 设 E 表示“药有效”， C 表示“感冒 2 次”。先验： $P(E) = 0.75$, $P(\bar{E}) = 0.25$ 。
* 似然： $P(C | E) = e^{-3} \frac{3^2}{2!}$, $P(C | \bar{E}) = e^{-5} \frac{5^2}{2!}$ 。
* 贝叶斯：

$$P(E | C) = \frac{P(E)P(C | E)}{P(E)P(C | E) + P(\bar{E})P(C | \bar{E})} = \frac{0.75 e^{-3} 9/2}{0.75 e^{-3} 9/2 + 0.25 e^{-5} 25/2} = \frac{27e^2}{27e^2 + 25} \approx 0.915.$$

- ★★★★★☆ 几何分布期望倒数：设 $X \sim \text{Ge}(p)$ ，证明 $E(\frac{1}{X}) = -\frac{p \ln p}{1-p}$ 。
* 代入密度： $E(1/X) = \sum_{k=1}^{\infty} \frac{1}{k} (1-p)^{k-1} p = \frac{p}{1-p} \sum_{k=1}^{\infty} \frac{(1-p)^k}{k}$ 。
* 级数公式： $\sum_{k=1}^{\infty} \frac{x^k}{k} = -\ln(1-x)$ （可由对几何级数 $\sum x^k = \frac{1}{1-x}$ 积分得到），取 $x = 1-p$ 得 $\sum \frac{(1-p)^k}{k} = -\ln p$ 。
* 代回即得 $E(1/X) = -\frac{p \ln p}{1-p}$ 。
- ★★★★★★ 二项分布的倒数期望： $X \sim b(n, p)$ ，证明 $E(\frac{1}{X+1}) = \frac{1 - (1-p)^{n+1}}{(n+1)p}$ 。
* 代入： $E(\frac{1}{X+1}) = \sum_{k=0}^n \frac{1}{k+1} C_n^k p^k (1-p)^{n-k}$ 。
* 用恒等式 $\frac{1}{k+1} C_n^k = \frac{1}{n+1} C_{n+1}^{k+1}$ ，得

$$E = \frac{1}{n+1} \sum_{k=0}^n C_{n+1}^{k+1} p^{k+1} (1-p)^{n-k} = \frac{1}{(n+1)p} \sum_{j=1}^{n+1} C_{n+1}^j p^j (1-p)^{n+1-j}.$$

- * 拆出全概率 1 再减去 $j = 0$ 项： $\sum_{j=0}^{n+1} C_{n+1}^j p^j (1-p)^{n+1-j} = 1$ ，故上式为 $\frac{1 - (1-p)^{n+1}}{(n+1)p}$ 。

2.5 常用连续分布

主要内容：正态、均匀、指数、伽马、贝塔分布的表达、期望方差、标准化。

• 知识点（熟练背诵）：

- 正态 $N(\mu, \sigma^2)$: 密度 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$; $E(X) = \mu$, $\text{Var}(X) = \sigma^2$; 标准化 $(X-\mu)/\sigma \sim N(0, 1)$ 。

含义：独立小扰动累加的极限分布，测量误差、身高、考试分常用此模型。

- 均匀 $U(a, b)$: $f = \frac{1}{b-a}$ ($a < x < b$), $E(X) = \frac{a+b}{2}$, $\text{Var}(X) = \frac{(b-a)^2}{12}$ 。含义：区间内任一点等可能，如“随机抽取一天中的时间点”。

- 指数 $\text{Exp}(\lambda)$: $f = \lambda e^{-\lambda x}$ ($x > 0$), $E(X) = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$, 无记忆性 $P(X > s+t | X > s) = P(X > t)$ 。含义：泊松过程的等待时间，常用于描述等待时间或寿命，如“下一次电话进来的间隔”。

- 伽马 $\text{Ga}(\alpha, \beta)$ (形状-尺度): $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$ ($x > 0$), $E(X) = \alpha\beta$, $\text{Var}(X) = \alpha\beta^2$ 。

含义：到第 α 次事件的累积等待时间，或多个独立指数和。

* 伽马函数: $\Gamma(r) = \int_0^\infty x^{r-1} e^{-x} dx$ ($r > 0$), 满足递推 $\Gamma(r+1) = r\Gamma(r)$, 整数时 $\Gamma(n) = (n-1)!$ 。

* 与指数的关系：当 $\alpha = 1, \beta = 1/\lambda$ 时, $\text{Ga}(1, 1/\lambda)$ 即 $\text{Exp}(\lambda)$ 。

* 应用直觉：可视为“累积 α 个独立指数等待时间”的和，或“频率已知但次数不确定的总耗时”，在排队/可靠性中频繁出现。

- 贝塔 $\text{Be}(\alpha, \beta)$: $f(x) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$ ($0 < x < 1$), $E(X) = \frac{\alpha}{\alpha+\beta}$, $\text{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$ 。含义：定义在 0-1 之间的比例型分布，常作“成功率”的先验或比例数据的模型；非常灵活，可呈现多种形状。

• 典型例题：

- ★★☆☆☆ 成绩正态分布反推分位数：考试成绩正态，10000 人，90 分以上有 359 人，60 分以下有 1151 人。录取 2500 人，求最低录取分。

* 标准化: $P(Z > z_1) = 359/10000 \Rightarrow z_1 \approx 1.8$; $P(Z < z_2) = 1151/10000 \Rightarrow z_2 \approx -1.2$ 。两点联立可解均值方差（把 90 映到 $1.8\sigma + \mu$, 60 映到 $-1.2\sigma + \mu$, 得 $\sigma \approx 10$, $\mu \approx 72$ ）。

* 录取 2500 人占比 0.25, 对应右尾 0.25, 查表 $z \approx 0.674$, 分数 $\mu + 0.674\sigma \approx 72 + 0.674 \times 10 \approx 78.8$ 。

- ★★★★★☆ $X \sim N(\mu, \sigma^2)$, 求 $E(|X - \mu|)$ 。

* 设 $Y = X - \mu \sim N(0, \sigma^2)$ 。 $E|Y| = 2 \int_0^\infty y \frac{1}{\sqrt{2\pi}\sigma} e^{-y^2/(2\sigma^2)} dy$ (偶对称, 乘 2 取正半轴)。

* 令 $t = y^2/(2\sigma^2)$, 则 $y = \sigma\sqrt{2t}$, $dy = \sigma \frac{1}{\sqrt{2t}} dt$ 。代入得

$$E|Y| = \frac{2}{\sqrt{2\pi}\sigma} \int_0^\infty \sigma\sqrt{2t} e^{-t} \sigma \frac{1}{\sqrt{2t}} dt = \frac{2\sigma^2}{\sqrt{2\pi}\sigma} \int_0^\infty e^{-t} dt = \sigma\sqrt{\frac{2}{\pi}}.$$

* 这对应“半正态分布”的期望：把正态折半取绝对值后，均值为 $\sigma\sqrt{2/\pi}$, 直观上“保留右半边的平均幅度”。

2.6 随机变量函数的分布

主要内容：随机变量变换公式，单调与非单调情形，CDF 法，对数正态分布。

• 知识点：

- 单调可逆变换: $Y = g(X)$ 且 g 单调, 密度 $f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right|$, 本质是把 $P(y < Y < y + dy)$ 换回 x 轴长度。

- 非单调: 用分布函数法 $F_Y(y) = P(g(X) \leq y)$, 按区间拆分 X 的解集, 再对每段求概率 (或对密度积分), 最后求得密度。

- 对数正态: 若 $\ln X \sim N(\mu, \sigma^2)$, 则 X 为对数正态; 其密度由链式变换得到, 用于“正值且相对乘性波动”的场景。

• 典型例题：

- ★★★☆☆ $X \sim U(-\frac{\pi}{2}, \frac{\pi}{2})$, 求 $Y = \cos X$ 的密度。
 - * Y 取值 $(0, 1]$, 因 $\cos$ 在 $(-\frac{\pi}{2}, \frac{\pi}{2})$ 上非单调。因此, 先求分布函数: $P(Y \leq y) = P(\cos X \leq y) = P(X \geq \arccos y)$ 。
 - * 对 $0 < y < 1$, 有 $F_Y(y) = \frac{\frac{\pi}{2} - \arccos y}{\pi}$ 。求导:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{1}{\pi} \cdot \frac{1}{\sqrt{1-y^2}} \cdot 1 = \frac{2}{\pi} \cdot \frac{1}{2\sqrt{1-y^2}} = \frac{2}{\pi\sqrt{1-y^2}}, \quad 0 < y < 1,$$

其他位置为 0。

2.7 分布的其他特征数

主要内容: k 阶原点矩/中心矩, 变异系数, 分位数/中位数, 偏度, 峰度。

- 知识点:
 - 原点矩 $\mu'_k = E(X^k)$, 中心矩 $\mu_k = E[(X - E(X))^k]$ 。含义: 原点矩是“直接的 k 次方平均”, 中心矩是“以均值为中心的 k 次方平均”, 用来量化幅度与分布形状。
 - 变异系数: $CV = \frac{\sigma}{|E(X)|}$, 量纲无关的离散度, 可比较不同单位或量级的波动, 如比较“身高相对波动”与“体重相对波动”。
 - 分位数/中位数: 分布函数到概率轴的反函数; 中位数 m 使 $P(X \leq m) = 0.5$, 直观是“把概率一刀切成两半”的位置。
 - 偏度系数: $\gamma_1 = \frac{E[(X - E(X))^3]}{\sigma^3}$, 度量左右偏斜: 正偏意味着右尾更长 (如收入分布), 负偏意味着左尾更长。
 - 峰度系数: $\gamma_2 = \frac{E[(X - E(X))^4]}{\sigma^4} - 3$ (超额峰度), 描述峰尖和尾厚: 正值 = 尖峰厚尾 (极端值更可能, 如金融收益), 负值 = 平顶短尾 (更集中, 极端更少)。
- 典型例题:
 - ★★★☆☆ $X \sim U(a, b)$ 。求 $\mu'_k = E(X^k)$, $\mu_k = E[(X - EX)^k]$ ($k = 1, 2, 3, 4$), 并求偏度、峰度。
 - * $E(X^k) = \frac{1}{b-a} \int_a^b x^k dx = \frac{b^{k+1} - a^{k+1}}{(k+1)(b-a)}$ 。
 - * $E(X) = \frac{a+b}{2}$, $\sigma^2 = \frac{(b-a)^2}{12}$ 。
 - * 中心矩: $\mu_1 = 0$; $\mu_2 = \sigma^2 = \frac{(b-a)^2}{12}$; $\mu_3 = 0$ (对称); $\mu_4 = \frac{(b-a)^4}{80}$ 。
 - * 偏度: $\gamma_1 = 0$ (对称分布)。峰度: $\gamma_2 = \frac{\mu_4}{\sigma^4} - 3 = \frac{(b-a)^4/80}{[(b-a)^2/12]^2} - 3 = -1.2$ 。

第三章 多维随机变量及其分布

3.1 多维随机变量及其联合分布

主要内容: 联合分布函数、联合分布列、联合密度、常见多维分布 (重点: 二元正态的基本形状与独立性条件)。

- 知识点:
 - 联合分布函数: $F_{X,Y}(x,y) = P(X \leq x, Y \leq y)$, 随 x, y 非减; $\lim_{x \rightarrow -\infty \text{ 或 } y \rightarrow -\infty} F = 0$, $\lim_{x, y \rightarrow +\infty} F = 1$ 。
 - 离散联合分布列: $p_{ij} = P(X = x_i, Y = y_j)$, $p_{ij} \geq 0$, $\sum_i \sum_j p_{ij} = 1$ 。
 - 联合密度: $f_{X,Y}(x,y) \geq 0$, $\iint f = 1$, 矩形概率 $P(a < X \leq b, c < Y \leq d) = \int_c^d \int_a^b f(x,y) dx dy$ 。
 - 二元正态 (常考点): (X, Y) 若联合正态, 则任一线性组合仍正态; 协方差为 0 时推出独立 (这是联合正态的特殊性质)。密度形状呈“椭圆等高线”。
- 典型例题:
 - ★★★☆☆ 设二维随机变量 (X, Y) 的联合密度为 $p(x,y) = \begin{cases} k, & 0 < x^2 < y < x < 1, \\ 0, & \text{其他} \end{cases}$ 。
 - 1) 求常数 k 。2) 求 $P(X > 0.5)$ 与 $P(Y < 0.5)$ 。

- * 归一化: $1 = \int_0^1 \int_{x^2}^x k dy dx = k \int_0^1 (x - x^2) dx = k [\frac{1}{2}x^2 - \frac{1}{3}x^3]_0^1 = k \cdot \frac{1}{6} \Rightarrow k = 6$ 。
- * $P(X > 0.5) = \int_{0.5}^1 \int_{x^2}^x 6 dy dx = \int_{0.5}^1 6(x - x^2) dx = [3x^2 - 2x^3]_{0.5}^1 = 1 - 0.5 = \frac{1}{2}$ 。
- * $P(Y < 0.5)$: 先固定 y , 约束给出 $y < x$ 且 $x^2 < y \Rightarrow y < x < \sqrt{y}$ 。因此

$$P(Y < 0.5) = \int_0^{0.5} \int_{x=y}^{\sqrt{y}} 6 dx dy = 6 \int_0^{0.5} (\sqrt{y} - y) dy = 6 \left[\frac{2}{3} y^{3/2} - \frac{1}{2} y^2 \right]_0^{0.5} = \sqrt{2} - \frac{3}{4} = \frac{4\sqrt{2}-3}{4}.$$

- ★★☆☆☆ 设 $Y \sim \text{Exp}(1)$ 。定义 $X_k = \begin{cases} 0, & Y \leq k \\ 1, & Y > k \end{cases}, k = 1, 2$ 。求 (X_1, X_2) 的联合分布列 (做成表格)。

- * 分段概率: $P(Y > 1) = e^{-1}, P(Y > 2) = e^{-2}$, 且 $Y \leq 1 \Rightarrow (X_1, X_2) = (0, 0); 1 < Y \leq 2 \Rightarrow (1, 0); Y > 2 \Rightarrow (1, 1)$, 状态 $(0, 1)$ 不可能。

- * 表格:

X_1	X_2	概率
0	0	$1 - e^{-1}$
1	0	$e^{-1} - e^{-2}$
1	1	e^{-2}
0	1	0

3.2 边际分布与随机变量的独立性

主要内容: 边际分布 (分布列/密度/分布函数) 求法, 独立性判别 (离散/连续)。

- 知识点:

- 边际分布: 离散 $p_X(x_i) = \sum_j p_{ij}$, 连续 $f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy$, 分布函数 $F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x,y)$; Y 同理。
- 独立性判别: 离散看 $p_{ij} \stackrel{?}{=} p_X(x_i)p_Y(y_j)$; 连续看 $f_{X,Y}(x,y) \stackrel{?}{=} f_X(x)f_Y(y)$ (在定义域内)。联合正态时协方差为 0 等价于独立; 一般情形零协方差不代表独立, 但独立一定协方差为 0。

- 典型例题:

- ★★☆☆☆ 设平面区域 D 由曲线 $y = 1/x$ 与直线 $y = 0, x = 1, x = e^2$ 围成, (X, Y) 在 D 上均匀分布。求 X 的边际密度。

- * 区域面积: $S = \int_{x=1}^{e^2} \int_{y=0}^{1/x} dy dx = \int_1^{e^2} \frac{1}{x} dx = 2$, 故联合密度为 $1/2$ (区域内常数)。

- * 边际: $f_X(x) = \int_0^{1/x} \frac{1}{2} dy = \frac{1}{2x}$, 定义域 $1 < x < e^2$, 其余为 0。

- ★★☆☆☆ 判断独立性:

$$1) p(x, y) = \frac{1}{\pi^2(1+x^2)(1+y^2)}, -\infty < x, y < \infty.$$

- * 可拆成 $[\frac{1}{\pi(1+x^2)}] \cdot [\frac{1}{\pi(1+y^2)}]$, 即 $f_X f_Y$, 故独立。

$$2) p(x, y) = \begin{cases} 24xy, & 0 < x < 1, 0 < y < 1, 0 < x+y < 1, \\ 0, & \text{其他} \end{cases}.$$

- * 先算边际: $f_X(x) = \int_0^{1-x} 24xy dy = 12x(1-x)^2, f_Y(y) = \int_0^{1-y} 24xy dx = 12y(1-y)^2$ 。

- * 若独立, 应有 $f_{X,Y}(x,y) = f_X(x)f_Y(y)$, 显然原密度不等于 $12x(1-x)^2 \cdot 12y(1-y)^2$, 故不独立 (也可用任一点代入对比)。

3.3 多维随机变量函数的分布

主要内容: 多维离散函数分布、最大最小的分布、卷积 (连续/离散)、变量变换与雅可比。

- 知识点:

- 离散卷积: $P(X+Y = k) = \sum_i P(X = i)P(Y = k-i)$; 连续卷积: $f_{X+Y}(z) = \int f_X(x)f_Y(z-x)dx$ 。
- 变量变换: $(U, V) = g(X, Y)$ 可逆时, $f_{U,V}(u, v) = f_{X,Y}(x, y) \left| \frac{\partial(x, y)}{\partial(u, v)} \right|$, 先找映射域, 再乘雅可比。

- 几何法：对简单区域，直接在新变量区域画图积分，有时比公式更直观。
- 典型例题：
 - ★★☆☆☆ 独立同分布 (X, Y) ，求 $Z = \max\{X, Y\}$ 的分布列。
 - 1) X 为 0-1 分布 ($P(X=1)=0.5$)。
 - * $P(Z=0) = P(X=0, Y=0) = 0.5 \times 0.5 = 0.25$; $P(Z=1) = 1 - 0.25 = 0.75$ 。
 - 2) $X \sim \text{Ge}(p)$, $P(X=k) = (1-p)^{k-1}p$, $k \geq 1$ 。
 - * $F_X(k) = 1 - (1-p)^k$, 故 $F_Z(k) = F_X(k)^2$, $P(Z=k) = F_Z(k) - F_Z(k-1)$ 。
 - * 展开: $P(Z=k) = [1 - (1-p)^k]^2 - [1 - (1-p)^{k-1}]^2 = (1-p)^{k-1}[1 - (1-p)][2 - (1-p)^{k-1} - (1-p)^k]$, 整理即可求任意 k 。
 - ★★★★★☆ (X, Y) 的联合密度 $p(x, y) = \begin{cases} e^{-(x+y)}, & x > 0, y > 0 \\ 0, & \text{其他} \end{cases}$ 。求 (1) $Z = \frac{X+Y}{2}$ 的密度; (2) $Z = Y - X$ 的密度。
 - * 变换法 (核心步骤): 设 $U = X+Y, V = Y-X$, 反变换 $X = \frac{U-V}{2}, Y = \frac{U+V}{2}$, Jacobi 行列式 $\left| \frac{\partial(x, y)}{\partial(u, v)} \right| = \frac{1}{2}$ 。
 - 定义域映射: $x > 0, y > 0 \Rightarrow U > 0$ 且 $-U < V < U$ (因为 $X > 0 \Rightarrow U > V$, $Y > 0 \Rightarrow U > -V$)。
 - 联合密度: $f_{U,V}(u, v) = e^{-u} \cdot \frac{1}{2}$, 域内 $u > 0, -u < v < u$, 域外 0。
 - (1) 先求 f_U : $f_U(u) = \int_{-u}^u \frac{1}{2} e^{-u} dv = u e^{-u}, u > 0$ 。再令 $z = u/2$, 换元时 $u = 2z, du = 2dz$, 所以 $f_Z(z) = f_U(2z) \cdot 2 = (2z) e^{-2z} \cdot 2 = 4z e^{-2z}$ (注意要连同 $du = 2dz$ 一起乘进去, 否则会少一倍。这里本质也是一个 1×1 的雅可比行列式)。
 - (2) $f_V(v) = \int_{|v|}^{\infty} \frac{1}{2} e^{-u} du = \frac{1}{2} e^{-|v|}, -\infty < v < \infty$ 。
 - * 也可使用几何积分法:
 - (1) 令 $z > 0$, 条件 $\frac{X+Y}{2} \leq z$ 等价于 $x+y \leq 2z, x > 0, y > 0$ 。面积积分:

$$F_Z(z) = \int_0^{2z} \int_0^{2z-x} e^{-(x+y)} dy dx = \int_0^{2z} e^{-x} [1 - e^{-(2z-x)}] dx,$$
 展开积分可得 $F_Z(z) = 1 - (2z+1)e^{-2z}$, 再求导得到 $f_Z(z) = 4ze^{-2z}$ 。
 - (2) 若 $v \geq 0$, 条件 $Y-X \leq v$ 等价于 $y \leq x+v$, 且 $x, y > 0$ 。积分:

$$F_V(v) = \int_0^{\infty} \int_0^{x+v} e^{-(x+y)} dy dx = 1 - e^{-v} (1 + \frac{v}{2}),$$
 对 $v < 0$ 类似可求得分布函数。最后对 F 求导即可得 $f_V(v) = \frac{1}{2} e^{-|v|}$, 与变换法一致。
 - ★★★★★☆ 某商品每周的需求量是独立的, 单周密度 $p_1(t) = \begin{cases} t e^{-t}, & t > 0 \\ 0, & t \leq 0 \end{cases}$ 。求两周需求量密度 $p_2(x)$ 、三周需求量密度 $p_3(x)$ 。
 - * 方法 1 (伽马分布): p_1 形如 $t^{\alpha-1} \frac{1}{\Gamma(\alpha)\beta^{\alpha}} e^{-t/\beta}$, 这里 $\alpha=2, \beta=1$, 即 $\text{Ga}(2, 1)$ 。独立同分布伽马的和仍是伽马, 形状参数相加、尺度不变: 两周 $\Rightarrow \text{Ga}(4, 1)$, 密度 $p_2(x) = \frac{1}{\Gamma(4)} x^{4-1} e^{-x} = \frac{x^3}{6} e^{-x}$; 三周 $\Rightarrow \text{Ga}(6, 1)$, $p_3(x) = \frac{1}{\Gamma(6)} x^{6-1} e^{-x} = \frac{x^5}{120} e^{-x}$ 。
 - * 方法 2 (卷积方法计算):
 - 两周: $p_2(x) = \int_0^x p_1(t) p_1(x-t) dt = \int_0^x t e^{-t} (x-t) e^{-(x-t)} dt = e^{-x} \int_0^x t(x-t) dt = e^{-x} \frac{x^3}{6}$ 。
 - 三周: $p_3(x) = \int_0^x p_2(t) p_1(x-t) dt = \int_0^x \frac{t^3}{6} e^{-t} \cdot (x-t) e^{-(x-t)} dt = e^{-x} \frac{1}{6} \int_0^x t^3 (x-t) dt = e^{-x} \frac{x^5}{120}$ 。
 - * 这里可以看出, 卷积公式 $f_{X+Y}(z) = \int f_X(x) f_Y(z-x) dx$ 可逐次滚动, 验证了“伽马形状参数可加”的结论。
 - ★★★★★☆ 设 X 与 Y 相互独立。求 $Z = X/Y$ 的密度。
 - 1) $X \sim U(0, 1), Y \sim \text{Exp}(1)$ 。

- * 取变换 $(U, V) = (X/Y, Y)$, 反变换 $X = UV, Y = V$, 雅可比 $|J| = \left| \det \begin{pmatrix} v & u \\ 0 & 1 \end{pmatrix} \right| = v$.
- * 联合密度: $f_{U,V}(u, v) = 1 \cdot e^{-v} \cdot v$, 域: $0 < u < 1/v$ (因 $0 < X < 1$) 且 $v > 0$.
- * 边际 $f_Z(u) = \int_0^{1/u} v e^{-v} dv = 1 - (1 + 1/u)e^{-1/u}$, $u > 0$.
- 2) $X \sim \text{Exp}(\lambda_1), Y \sim \text{Exp}(\lambda_2)$.
 - * 同样设 $U = X/Y, V = Y$, 反变换如上, 雅可比 v .
 - * 联合密度: $f_{U,V}(u, v) = \lambda_1 e^{-\lambda_1 uv} \cdot \lambda_2 e^{-\lambda_2 v} \cdot v$, $u > 0, v > 0$.
 - * 边际: $f_Z(u) = \int_0^\infty \lambda_1 \lambda_2 v e^{-(\lambda_1 u + \lambda_2)v} dv = \frac{\lambda_1 \lambda_2}{(\lambda_1 u + \lambda_2)^2}$, $u > 0$.
- ★★★★★ X_1, X_2 独立同分布, 密度 $p(x) = \begin{cases} 2x, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$. 求 $Z = \max\{X_1, X_2\} - \min\{X_1, X_2\}$ 的分布.
 - * 思路: $Z = |X_1 - X_2|$, 先求差 $W = X_1 - X_2$ 的密度, 进一步即可得到 Z .
 - * 求 f_W :
 - 对给定 $w > 0$, 有 $W = w \Rightarrow X_1 = X_2 + w$, 必须满足 $0 < x_2 < 1$ 且 $0 < x_2 + w < 1$, 即 $w < x_1 < 1, 0 < x_2 < 1 - w$. 用卷积公式 $f_W(w) = \int f_{X_1}(x) f_{X_2}(x - w) dx$, 积分范围 $x \in [w, 1]$.
 - 列式: $f_W(w) = \int_w^1 2x \cdot 2(x - w) dx$, 前一因子来自 X_1 的密度, 后一因子来自 X_2 的密度. 积分得 $f_W(w) = \frac{4}{3} - 2w + \frac{2}{3}w^3$, $0 < w < 1$; 负半轴对称 $f_W(-w) = f_W(w)$, 其余为 0.
 - * 求 f_Z : $Z = |W|$, 因此 $f_Z(z) = f_W(z) + f_W(-z) = 2f_W(z)$, $z > 0$, 得到 $f_Z(z) = \frac{4}{3}z^3 - 4z + \frac{8}{3}$, $0 < z < 1$, 域外 0.
 - * 积分得分布函数 $F_Z(z) = \int_0^z f_Z(t) dt = \frac{8}{3}z - 2z^2 + \frac{1}{3}z^4$, $0 < z < 1$, 验证: 有 $F_Z(0) = 0, F_Z(1) = 1$.

3.4 多维随机变量的特征数

主要内容: 期望向量, 协方差/相关系数, 协方差矩阵, 线性变换下的运算规则.

- 知识点:
 - 协方差: $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$, 刻画“线性同涨同跌”; 对称, $\text{Cov}(X, X) = \text{Var}(X)$.
 - 相关系数: $\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1]$, 量纲无关.
 - 方差分解: $\text{Var}(X \pm Y) = \sigma_X^2 + \sigma_Y^2 \pm 2\text{Cov}(X, Y)$.
- 典型例题:
 - ★★★★★☆☆ (X, Y) 在以 $(0, 1), (1, 0), (1, 1)$ 为顶点的三角形区域内均匀分布. 求 $E(X + Y)$, $\text{Var}(X + Y)$.
 - * 先把区域说清楚: 直角三角形, 底边在 x 轴从 0 到 1, 高在 y 轴从 0 到 1, 斜边是 $x + y = 1$. 面积 $S = \frac{1}{2}$, 故联合密度常数为 2.
 - * 边际: $f_X(x) = \int_{1-x}^1 2 dy = 2x$ ($0 < x < 1$), $f_Y(y) = \int_{1-y}^1 2 dx = 2y$ (对称).
 - * 期望: $E(X) = \int_0^1 x \cdot 2x dx = \frac{2}{3}$, $E(Y) = \frac{2}{3}$, 故 $E(X + Y) = \frac{4}{3}$.
 - * $E(X^2) = \int_0^1 x^2 \cdot 2x dx = \frac{1}{2}$, $E(Y^2) = \frac{1}{2}$. $E(XY) = \int_0^1 \int_{1-x}^1 2xy dy dx = \int_0^1 2x \left[\frac{1}{2}(1^2 - (1-x)^2) \right] dx = \int_0^1 x[1 - (1 - 2x + x^2)] dx = \int_0^1 (2x^2 - x^3) dx = \frac{5}{12}$.
 - * 协方差: $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = \frac{5}{12} - \frac{4}{9} = -\frac{1}{36}$.
 - * 方差: $\text{Var}(X) = E(X^2) - (E(X))^2 = \frac{1}{2} - \frac{4}{9} = \frac{1}{18}$, 同理 $\text{Var}(Y) = \frac{1}{18}$. 方差分解: $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) = \frac{1}{18} + \frac{1}{18} + 2(-\frac{1}{36}) = \frac{1}{18}$.
 - ★★★★★★ 系统寿命: n 个独立部件, $X_i \sim \text{Exp}(\lambda)$.
 - 1) 串联系统 (任一损坏即停): $T = \min\{X_i\}$.
 - * 分析: 因为独立指数的“最小值”服从参数为各自参数和的指数, 直观是“所有部件都在同时倒计时, 最快的那个先触发”, 故 $T \sim \text{Exp}(n\lambda)$, $E(T) = \frac{1}{n\lambda}$ (也可由 $P(T > t) = P(\text{全部} > t) = e^{-\lambda t \cdot n}$ 推出).
 - 2) 并联系统 (至少有一个在工作): $T = \max\{X_i\}$.
 - * 分布函数: $F_T(t) = P(\text{全部} \leq t) = [1 - e^{-\lambda t}]^n$ (每个部件在 t 前坏掉的概率是 $1 - e^{-\lambda t}$).

- * 密度: $f_T(t) = \frac{d}{dt}F_T(t) = n\lambda e^{-\lambda t}[1 - e^{-\lambda t}]^{n-1}$ 。
- * 计算期望: (注意期望可表达为生存函数的积分)

$$E(T) = \int_0^\infty P(T > t)dt = \int_0^\infty (1 - [1 - e^{-\lambda t}]^n)dt.$$

用二项式定理展开 $[1 - e^{-\lambda t}]^n = \sum_{k=0}^n C_n^k (-1)^k e^{-k\lambda t}$, 因此

$$1 - [1 - e^{-\lambda t}]^n = \sum_{k=1}^n C_n^k (-1)^{k+1} e^{-k\lambda t}.$$

逐项积分: $\int_0^\infty e^{-k\lambda t} dt = \frac{1}{k\lambda}$, 得到

$$E(T) = \sum_{k=1}^n (-1)^{k+1} \frac{C_n^k}{k\lambda}.$$

- ★★★★★☆ $X_i \sim U(0, \theta)$ 独立同分布, $Y = \max\{X_i\}$, $Z = \min\{X_i\}$ 。求 $E(Y)$, $E(Z)$ 。
- * Y : $F_Y(y) = P(\text{全部} \leq y) = (\frac{y}{\theta})^n$ ($0 < y < \theta$), 密度 $f_Y(y) = \frac{d}{dy}F_Y(y) = \frac{n}{\theta}(\frac{y}{\theta})^{n-1}$ 。积分得 $E(Y) = \int_0^\theta y f_Y(y) dy = \frac{n\theta}{n+1}$ 。
- * Z : $P(Z > z) = P(\text{全部} > z) = [1 - \frac{z}{\theta}]^n$, 对 $z \in (0, \theta)$; 密度 $f_Z(z) = \frac{d}{dz}(1 - [1 - \frac{z}{\theta}]^n) = \frac{n}{\theta}[1 - \frac{z}{\theta}]^{n-1}$ 。积分得 $E(Z) = \int_0^\theta z f_Z(z) dz = \frac{\theta}{n+1}$ 。
- ★★☆☆☆ 已知 $E(X) = -2$, $E(Y) = 2$, $\sigma_X = 1$, $\sigma_Y = 2$, $\rho = -0.5$ 。估计 $P(|X+Y| \geq 6)$ 的上界。
- * $\text{Cov} = \rho\sigma_X\sigma_Y = -1$, $\text{Var}(X+Y) = 1^2 + 2^2 + 2(-1) = 3$ 。切比雪夫: $P(|X+Y - E(X+Y)| \geq 6 - 0) = P(|X+Y| \geq 6) \leq \frac{3}{6^2} = \frac{1}{12}$ 。
- ★★★★★☆☆ 任意两两相关系数都为 ρ 的 $X_1, \dots, X_n$ 。证明 $\rho \geq -\frac{1}{n-1}$ 。
- * 取 $S = \sum_{i=1}^n X_i$, 展开方差:

$$\text{Var}(S) = \sum_{i=1}^n \sigma_i^2 + 2\rho \sum_{i<j} \sigma_i \sigma_j.$$

把交叉项写成“根号方差的乘积”是为了后面放缩: $\sigma_i \sigma_j = \sqrt{\sigma_i^2} \sqrt{\sigma_j^2}$ 。

- * 放缩思路: 对每一对 (i, j) , 有 $2\sigma_i \sigma_j \leq \sigma_i^2 + \sigma_j^2$ 。因此

$$2\rho \sigma_i \sigma_j \geq 2\rho \frac{\sigma_i^2 + \sigma_j^2}{2} = \rho(\sigma_i^2 + \sigma_j^2) \quad (\rho \leq 1).$$

把所有 $\frac{n(n-1)}{2}$ 对求和, 会使每个 σ_i^2 被加了 $(n-1)$ 次:

$$2\rho \sum_{i<j} \sigma_i \sigma_j \geq \rho(n-1) \sum_{i=1}^n \sigma_i^2.$$

- * 代回原式:

$$\text{Var}(S) \geq \sum_{i=1}^n \sigma_i^2 + \rho(n-1) \sum_{i=1}^n \sigma_i^2 = [1 + (n-1)\rho] \sum_{i=1}^n \sigma_i^2.$$

方差非负, 且 $\sum \sigma_i^2 > 0$, 故 $1 + (n-1)\rho \geq 0 \Rightarrow \rho \geq -\frac{1}{n-1}$ 。

3.5 条件分布与条件期望

主要内容：条件分布/条件密度，条件期望，重期望公式，连续版全概率，方差分解。

• 知识点：

- 条件分布：离散 $P(X = x | Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}$ ；连续 $f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$ 。
- 重期望（迭代期望）： $E(X) = E[E(X | Y)]$ ，对应全概率在期望层面的展开。
- 方差分解公式： $\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$ 。

• 典型例题：

- ★★★☆☆ 设 X 是一天内出生总数， Y 是其中男婴数。联合分布：

$$P(X = n, Y = m) = e^{-14} \frac{7.14^m 6.86^{n-m}}{m!(n-m)!}, \quad m = 0, 1, \dots, n, \quad n = 0, 1, 2, \dots$$

求条件分布列 $P(Y = m | X = n)$ 。

* 先求 X 的边际：对给定 n ,

$$P(X = n) = \sum_{m=0}^n e^{-14} \frac{7.14^m 6.86^{n-m}}{m!(n-m)!} = e^{-14} \frac{1}{n!} \sum_{m=0}^n C_n^m 7.14^m 6.86^{n-m} = e^{-14} \frac{(7.14 + 6.86)^n}{n!}.$$

实际上，这正是均值 14 的泊松分布的标准形式，故 $X \sim \text{Pois}(14)$ 。

* 再求条件分布：

$$P(Y = m | X = n) = \frac{P(X = n, Y = m)}{P(X = n)} = \frac{e^{-14} \frac{7.14^m 6.86^{n-m}}{m!(n-m)!}}{e^{-14} \frac{14^n}{n!}} = \frac{n!}{m!(n-m)!} \left(\frac{7.14}{14}\right)^m \left(\frac{6.86}{14}\right)^{n-m}.$$

识别为二项分布 $b(n, 0.51)$ ，所以 $P(Y = m | X = n) = C_n^m (0.51)^m (0.49)^{n-m}$, $m = 0, 1, \dots, n$ 。

- ★★★☆☆ X, Y 独立同分布，在下列两种情况下求 $P(X = k | X + Y = m)$ 。

1) $X, Y \sim \text{Ge}(p)$ 。

* 联合： $P(X = k, X + Y = m) = P(X = k)P(Y = m - k) = (1 - p)^{k-1}p \cdot (1 - p)^{m-k-1}p$, $k = 1, \dots, m - 1$ 。

* 边际： $P(X + Y = m) = \sum_{k=1}^{m-1} (1 - p)^{m-2} p^2 = (m - 1)(1 - p)^{m-2} p^2$ （实际上，这就是 $\text{Nb}(r = 2, p)$ 的分布列）。

* 条件： $P(X = k | X + Y = m) = \frac{(1 - p)^{m-2} p^2}{(m - 1)(1 - p)^{m-2} p^2} = \frac{1}{m - 1}$ ，在 $k = 1, \dots, m - 1$ 上均匀。

2) $X, Y \sim b(n, p)$ 。

* 联合： $P(X = k, X + Y = m) = P(X = k)P(Y = m - k) = C_n^k p^k (1 - p)^{n-k} \cdot C_n^{m-k} p^{m-k} (1 - p)^{n-m+k}$ 。

* 边际： $P(X + Y = m) = C_{2n}^m p^m (1 - p)^{2n-m}$ （因为两独立二项之和是参数 $2n, p$ 的二项）。

* 条件： $P(X = k | X + Y = m) = \frac{C_n^k C_n^{m-k}}{C_{2n}^m}$, $k = 0, \dots, m$ ，恰是超几何分布（从 $2n$ 次试验中已知有 m 次成功，问前 n 次里有多少成功）。

- ★★★☆☆ 设 $X \sim U(1, 2)$ ，在 $X = x$ 条件下 $Y | X = x \sim \text{Exp}(x)$ ，证明 $Z = XY \sim \text{Exp}(1)$ 。

* 这道题有点搞脑子，但是关键想法是：条件在 $X = x$ 下，把 $Z = xY$ 视作对 Y 的线性放缩，直接用一维变换即可把条件密度算出来。结论会发现与 x 无关，再对 x 积分，密度仍保持指数型。

* 条件密度： $Y | X = x$ 的密度为 $f_{Y|X}(y | x) = x e^{-xy}$ ($y > 0$)。令 $Z = xY$ ，则 $y = z/x$ ，雅可比 $|dy/dz| = 1/x$ ，所以

$$f_{Z|X}(z | x) = f_{Y|X}(z/x | x) \cdot \frac{1}{x} = x e^{-x(z/x)} \cdot \frac{1}{x} = e^{-z}, \quad z > 0.$$

条件密度完全不含 x ，已经是参数 1 的指数分布。

* 最后可以借此来进一步计算无条件密度: $f_X(x) = 1$ ($1 < x < 2$)。对 x 积分:

$$f_Z(z) = \int_1^2 f_{Z|X}(z|x)f_X(x)dx = \int_1^2 e^{-z} dx = e^{-z}, \quad z > 0.$$

因此 $Z \sim \text{Exp}(1)$, 证毕。

- ★★★★★☆ 设 $\{X_i\}$ 独立同分布, $E(X_1) = \mu$, $\text{Var}(X_1) = \sigma^2 < \infty$; N 只取正整数, $E(N) < \infty$, $\text{Var}(N) < \infty$, 且 N 与全部 X_i 独立。证明

$$\text{Var}\left(\sum_{i=1}^N X_i\right) = \text{Var}(N)[E(X_1)]^2 + E(N)\text{Var}(X_1).$$

- * 思路: 对随机和常用套路是“先对 N 条件化”, 再用方差分解公式。条件后求和变成固定项数的独立同分布求和, 方差可直接写出。
- * 先算条件期望与方差: 在给定 $N = n$ 时, $S_N = \sum_{i=1}^N X_i$ 满足 $E(S_N | N = n) = n\mu$, $\text{Var}(S_N | N = n) = n\sigma^2$ (独立同分布求和方差线性相加)。
- * 方差分解:
- $$\text{Var}(S_N) = E[\text{Var}(S_N | N)] + \text{Var}(E[S_N | N]).$$
- 第一项 $E[\text{Var}(S_N | N)] = E[N\sigma^2] = \sigma^2 E(N)$; 第二项 $\text{Var}(E[S_N | N]) = \text{Var}(N\mu) = \mu^2 \text{Var}(N)$ 。
- * 合并即得 $\text{Var}(S_N) = \mu^2 \text{Var}(N) + \sigma^2 E(N)$, 与题式一致。

第四章 大数定律与中心极限定理

4.1 随机变量序列的两种收敛性

主要内容: 依概率收敛、按分布收敛 (弱收敛), 两者的基本性质与典型操作, 弱大数定律的思路 (切比雪夫控制波动)。

• 知识点:

- 依概率收敛 $X_n \xrightarrow{P} X$: 对任意 $\varepsilon > 0$, $P(|X_n - X| > \varepsilon) \rightarrow 0$ 。直观: 样本越大, X_n 与 X 偏差超过任意小阈值的概率趋零。
- 按分布收敛 $X_n \xrightarrow{d} X$: 分布函数 $F_{X_n}(x) \rightarrow F_X(x)$ 于 F_X 的所有连续点。强调“整体分布形状”逼近, 允许点态震荡。
- 关系: 依概率收敛 $\Rightarrow$ 按分布收敛, 反之不一定。常用替换性质 (连续映射定理): 若 $X_n \xrightarrow{P} X$, $Y_n \xrightarrow{P} Y$ 且 g 连续, 则 $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$ 。Slutsky 定理: 若 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{P} c$ (常数), 则 $X_n + Y_n \xrightarrow{d} X + c$, $X_n Y_n \xrightarrow{d} cX$, $\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}$ 。
- 线性、乘积稳定性: 对和/积常用“三角不等式 + 拆加减”或“平方恒等式”控制, 用 $\varepsilon/2$ 夹击概率即可证明收敛性保持。
- 弱大数定律 (切比雪夫版): 独立同分布且方差有限, 样本均值 $\bar{X}_n \xrightarrow{P} \mu$ 。证明套路: $\text{Var}(\bar{X}_n) = \sigma^2/n$, 然后切比雪夫给出概率上界 $\rightarrow 0$, 进而直接得证。

• 典型例题:

- ★★★★★☆ 若 $X_n \xrightarrow{P} X$, $Y_n \xrightarrow{P} Y$, 证明 (1) $X_n + Y_n \xrightarrow{P} X + Y$; (2) $X_n Y_n \xrightarrow{P} XY$ 。

* (1) 三角不等式: $|X_n + Y_n - (X + Y)| \leq |X_n - X| + |Y_n - Y|$ 。取任意 $\varepsilon > 0$, 有

$$P(|X_n + Y_n - (X + Y)| > \varepsilon) \leq P(|X_n - X| > \varepsilon/2) + P(|Y_n - Y| > \varepsilon/2) \rightarrow 0.$$

* (2) 乘积用“先证平方, 再用恒等式”更直观:

- 1) 先证 $X_n^2 \xrightarrow{P} X^2$ 。注意 X 也是随机变量, 不是定值, 所以才会出现 $P(|X| > \text{阈值})$ 这样的概率。因为 $|X_n^2 - X^2| = |X_n - X||X_n + X|$, 对任意 $\varepsilon, \delta > 0$, 先取大 M 使 $P(|X| > (M-1)/2) < \delta$, 再取 N 使 $n > N \Rightarrow P(|X_n - X| \geq 1) < \delta$ 。分解

$$P(|X_n^2 - X^2| \geq \varepsilon) \leq P(|X_n - X| \geq \varepsilon/M) + P(|X_n + X| > M).$$

第二项 $\leq P(|X_n - X| \geq 1) + P(|X| > (M-1)/2) < 2\delta$; 第一项因 $X_n \xrightarrow{P} X$ 也可小于 δ , 合计 $< 3\delta$, 由 δ 任意性得证。 $Y_n^2 \xrightarrow{P} Y^2$ 同理。

- 2) 由 (1) 得 $X_n + Y_n \xrightarrow{P} X + Y$, 再对其平方重复第 1) 的推理, 得 $(X_n + Y_n)^2 \xrightarrow{P} (X + Y)^2$ 。
- 3) 用恒等式 $2X_n Y_n = (X_n + Y_n)^2 - X_n^2 - Y_n^2$ 。右边三项各自依概率收敛, 其差也依概率收敛到 $(X + Y)^2 - X^2 - Y^2 = 2XY$, 所以 $X_n Y_n \xrightarrow{P} XY$ 。
- ★★★★★ 若 $X_n \xrightarrow{d} X$, $a_n \rightarrow a$, $b_n \rightarrow b$, 证明 $a_n X_n + b_n \xrightarrow{d} aX + b$ 。
- * 可以采用如下思路:
- 1) 常数倍的分布收敛: 若 $a \neq 0$, $P(aX_n \leq x) = P(X_n \leq x/a) = F_{X_n}(x/a)$ 。当 x 是 aX 的连续点时, x/a 是 X 的连续点, 故 $F_{aX_n}(x) \rightarrow F_{aX}(x)$, 即 $aX_n \xrightarrow{d} aX$; 若 $a = 0$, 则 $aX_n \equiv 0$, 显然按分布收敛到 0。
 - 2) 同时, 注意到: $a_n \rightarrow a$, $b_n \rightarrow b$, 又因为常数趋 0 乘以概率收敛的变量仍概率收敛到 0, 故有 $(a_n - a)X_n \xrightarrow{P} 0$, 再加上常数 $b_n - b \rightarrow 0$, 得到 $(a_n - a)X_n + (b_n - b) \xrightarrow{P} 0$ 。
 - 3) 设 $U_n = aX_n \xrightarrow{d} aX$, $V_n = (a_n - a)X_n + (b_n - b) \xrightarrow{P} 0$ 。然后使用 Slutsky 定理: 分布收敛的 U_n 加上概率收敛到常数 0 的 V_n , 和仍按分布收敛到 aX 。再平移常数 b , 得到 $a_n X_n + b_n \xrightarrow{d} aX + b$ 。
- ★★☆☆☆ 设 X_n 独立同分布, $E(X_n) = \mu$, $\text{Var}(X_n) = \sigma^2 < \infty$ 。证明 $Y_n = \frac{2}{n(n+1)} \sum_{k=1}^n kX_k \xrightarrow{P} \mu$ 。
- * 先算均值: $E(Y_n) = \frac{2}{n(n+1)} \sum_{k=1}^n k\mu = \mu$, 所以目标值就是 μ 。
- * 再算方差: 系数 $c_k = \frac{2k}{n(n+1)}$, 因独立, $\text{Var}(Y_n) = \sigma^2 \sum c_k^2 = \sigma^2 \frac{4}{n^2(n+1)^2} \sum_{k=1}^n k^2$ 。用 $\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}$, 得到
- $$\text{Var}(Y_n) = \sigma^2 \cdot \frac{4}{n^2(n+1)^2} \cdot \frac{n(n+1)(2n+1)}{6} = \frac{4\sigma^2(2n+1)}{6n(n+1)} \rightarrow 0.$$
- * 切比雪夫: $P(|Y_n - \mu| > \varepsilon) \leq \frac{\text{Var}(Y_n)}{\varepsilon^2} \rightarrow 0$, 故依概率收敛。

4.2 特征函数

主要内容: 特征函数定义与直观、基本性质 (值域界、连续性)、利用特征函数求矩、唯一性与逆转公式、独立和与可加性、收敛定理 (Levy)。

• 知识点:

- 定义: $\varphi_X(t) = E(e^{itX})$ (所有 $t \in \mathbb{R}$)。
- 基本性质: $\varphi_X(0) = 1$; $|\varphi_X(t)| \leq 1$ 且一致连续; 对称分布 $p(x) = p(-x)$ 有实偶特征函数; 独立求和可乘: $X \perp Y \Rightarrow \varphi_{X+Y} = \varphi_X \varphi_Y$; 线性变换: $\varphi_{aX+b}(t) = e^{itb} \varphi_X(at)$ 。
- 矩公式 (常用特例): 若 $E|X| < \infty$, $E(X) = \frac{1}{i} \varphi'_X(0)$; 若二阶矩存在, $E(X^2) = -\varphi''_X(0)$, $\text{Var}(X) = -\varphi''_X(0) - (\frac{1}{i} \varphi'_X(0))^2$ 。
- 唯一性与逆转: 特征函数唯一决定分布; 连续型在可积条件下 $f_X(x) = \frac{1}{2\pi} \int e^{-itx} \varphi_X(t) dt$ 。
- Levy 连续性定理: 若 $\varphi_{X_n}(t) \rightarrow \varphi(t)$ 且极限是某分布的特征函数, 则 $X_n \xrightarrow{d} X$ 且 φ 就是 X 的特征函数。
- 下列常见分布的特征函数最好背诵:
 - * 伯努利 Bernoulli(p): $\varphi(t) = (1-p) + pe^{it}$ 。
 - * 二项 $b(n, p)$: $[(1-p) + pe^{it}]^n$ 。
 - * 泊松 Poisson(λ): $e^{\lambda(e^{it}-1)}$ 。
 - * 正态 $N(\mu, \sigma^2)$: $e^{it\mu - \frac{1}{2}\sigma^2 t^2}$ 。
 - * 均匀 $U(a, b)$: $\frac{e^{itb} - e^{ita}}{it(b-a)}$ 。

- * 指数 $\text{Exp}(\lambda)$: $\frac{\lambda}{\lambda - it}$ 。
- * 伽马 $\text{Ga}(\alpha, \lambda)$ (形状-率): $(1 - \frac{it}{\lambda})^{-\alpha}$ 。
- * 几何 (支持 $1, 2, \dots$) $\text{Ge}(p)$: $\frac{pe^{it}}{1 - (1-p)e^{it}}$ 。
- * 负二项 $\text{Nb}(r, p)$: $\left(\frac{pe^{it}}{1 - (1-p)e^{it}}\right)^r$ 。
- * 柯西 (尺度 a): $e^{-a|t|}$ 。

• 典型例题:

- ★★☆☆☆ $X \sim \text{Ge}(p)$, 求特征函数并由此求 $E(X)$ 、 $\text{Var}(X)$ 。

* 直接代入:

$$\varphi_X(t) = \sum_{k=1}^{\infty} (1-p)^{k-1} p e^{itk} = \frac{pe^{it}}{1 - (1-p)e^{it}}, \quad |(1-p)e^{it}| < 1.$$

- * 求矩公式: $E(X) = \frac{1}{i} \varphi'_X(0) = \frac{1}{p}$; $E(X^2) = -\varphi''_X(0) = \frac{2-p}{p^2}$, 于是 $\text{Var}(X) = E(X^2) - [E(X)]^2 = \frac{1-p}{p^2}$ 。

* ★★☆☆☆ 求下列分布的特征函数, 并求期望、方差。

- 1) $f_1(x) = \frac{a}{2} e^{-a|x|}$ ($a > 0$, 双边指数/Laplace 分布)。

* 拆正负半轴积分即可。

$$\varphi_1(t) = \int_{-\infty}^0 e^{itx} \frac{a}{2} e^{ax} dx + \int_0^{\infty} e^{itx} \frac{a}{2} e^{-ax} dx.$$

前一段 $= \frac{a}{2} \cdot \frac{1}{a+it}$, 后一段 $= \frac{a}{2} \cdot \frac{1}{a-it}$, 相加得 $\varphi_1(t) = \frac{a^2}{a^2 + t^2}$ 。因为密度偶对称, $E(X) = 0$;

用 $-\varphi''_1(0) = \frac{2}{a^2}$ 得 $\text{Var}(X) = \frac{2}{a^2}$ 。

- 2) $f_2(x) = \frac{a}{\pi} \frac{1}{x^2 + a^2}$ ($a > 0$)。

* 这是柯西分布, 特征函数 $\varphi_2(t) = e^{-a|t|}$ 。期望、方差不存在 (重尾 $1/x^2$), 因此不能用导数求矩。

- ★★☆☆☆ 用特征函数证明二项分布可加性: $X \sim b(n, p)$, $Y \sim b(m, p)$ 独立, 证明 $X + Y \sim b(n+m, p)$ 。

* 根据公式: $\varphi_X(t) = [(1-p) + pe^{it}]^n$, $\varphi_Y(t) = [(1-p) + pe^{it}]^m$ 。独立求和后相乘得到 $[(1-p) + pe^{it}]^{n+m}$, 正好是 $b(n+m, p)$ 的特征函数, 唯一性得结论。

- ★★☆☆☆ 用特征函数证明伽马分布可加性: $X \sim \text{Ga}(\alpha_1, \lambda)$, $Y \sim \text{Ga}(\alpha_2, \lambda)$ 独立 (率参数同为 λ)。

* 根据公式: $\varphi_X(t) = (1 - \frac{it}{\lambda})^{-\alpha_1}$, $\varphi_Y(t) = (1 - \frac{it}{\lambda})^{-\alpha_2}$ 。乘积保持同形, 幂次相加, 得到 $(1 - \frac{it}{\lambda})^{-(\alpha_1 + \alpha_2)}$, 对应 $\text{Ga}(\alpha_1 + \alpha_2, \lambda)$ 。

- ★★☆☆☆ 设连续型 X 密度 $p(x)$ 。证明 $p(x)$ 关于原点对称 $\Leftrightarrow$ 特征函数 $\varphi_X(t)$ 为实的偶函数。

* 必要性: 若 $p(x) = p(-x)$, 则

$$\varphi_X(t) = \int e^{itx} p(x) dx = \int (\cos tx + i \sin tx) p(x) dx.$$

奇偶性: $\cos$ 偶, $\sin$ 奇, 密度又偶, 对称积分中 $\sin$ 项为 0, 剩下实的偶函数 $\int \cos(tx) p(x) dx$ 。

* 充分性: 若 φ_X 为实偶函数, 则其傅里叶反变换 (逆转公式) 给出的密度必为偶:

$$p(x) = \frac{1}{2\pi} \int e^{-itx} \varphi_X(t) dt = \frac{1}{2\pi} \int \cos(tx) \varphi_X(t) dt,$$

被积函数对 t 偶, 积分结果对 x 也偶, 说明 $p(x) = p(-x)$ 。

- ★★★★★☆ (泊松定理) 设 $X_n \sim b(n, p_n)$, 若 $np_n \rightarrow \lambda$, 证明 $P(X_n = k) \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}$.
 - * 特征函数法: $\varphi_{X_n}(t) = [1 - p_n + p_n e^{it}]^n = [1 + p_n(e^{it} - 1)]^n$.
 - * 取对数:

$$\ln \varphi_{X_n}(t) = n \ln [1 + p_n(e^{it} - 1)] \approx n[p_n(e^{it} - 1) - \frac{1}{2}p_n^2(e^{it} - 1)^2 + o(p_n^2)].$$

因 $np_n \rightarrow \lambda$ 且 $np_n^2 \rightarrow 0$, 主导项为 $\lambda(e^{it} - 1)$, 其余高阶项为 0.

- * 极限: $\varphi_{X_n}(t) \rightarrow e^{\lambda(e^{it} - 1)}$, 这正是 $\text{Pois}(\lambda)$ 的特征函数. 由 Levy 定理, $X_n \xrightarrow{d} \text{Pois}(\lambda)$, 概率质量点逐点收敛即得结论.

4.3 大数定律

主要内容: 几种常见大数定律 (切比雪夫/辛钦/Kolmogorov/格涅坚科) 及应用场景, 弱/强的直观差别, 常用证明套路 (方差控制、三系数).

- 知识点:
 - 大数定律要点: 样本平均 “稳定” 地逼近期望. 弱大数定律 (如切比雪夫版) 强调概率收敛; 强大数定律强调 “几乎处处收敛” ($\xrightarrow{a.s.}$ 表示概率为 1 的样本路径上收敛, 即 almost sure, 允许存在极少数 “倒霉” 的路径不收敛, 但这些路径发生的总概率必须严格等于 0).
 - 切比雪夫版 (独立同分布, 方差有限): $\bar{X}_n \xrightarrow{P} \mu$, 核心是 $\text{Var}(\bar{X}_n) = \sigma^2/n$.
 - 辛钦强大数定律: 独立同分布且期望存在, 就有 $\bar{X}_n \xrightarrow{a.s.} \mu$, 不要求方差有限.
 - Kolmogorov 三系数判别 (一般独立): 若 $\sum \text{Var}(X_n/n) < \infty$, 可推出样本平均几乎处处收敛, 常用于不等方差情形.
 - 应试提示: 遇到 “独立 + 方差有限 + 样本均值” 优先尝试切比雪夫; 若只给期望, 回忆辛钦; 若给可求特定和/系数, 可考虑 Kolmogorov 或 Toeplitz 类结果.

• 典型例题:

- ★★★★★☆☆ 设独立序列 X_n , $P(X_n = 1) = p_n$, $P(X_n = 0) = 1 - p_n$. 证明 $\{X_n\}$ 服从大数定律.
 - * 样本均值 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, 考察 $a_n = \frac{1}{n} \sum_{i=1}^n p_i = E(\bar{X}_n)$, 作为目标极限候选.
 - * 方差: $\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum p_i(1 - p_i) \leq \frac{1}{4n}$ (用 $p(1 - p) \leq 1/4$).
 - * 切比雪夫: $P(|\bar{X}_n - a_n| > \varepsilon) \leq \frac{1}{4n\varepsilon^2} \rightarrow 0$, 所以 $\bar{X}_n \xrightarrow{P} \lim a_n$ (若 a_n 本身有极限).
- ★★★★★★ (格涅坚科大数定律) 设 $Y_n = \frac{1}{n} \sum_{i=1}^n X_i$, $a_n = \frac{1}{n} \sum_{i=1}^n E(X_i)$. 证明: $\{X_n\}$ 服从大数定律 $\Leftrightarrow \lim E(\frac{(Y_n - a_n)^2}{1 + (Y_n - a_n)^2}) = 0$.
 - * 可设权函数 $f(t) = \frac{t^2}{1 + t^2}$.
 - * 充分性 (右推左): 若 $E(\frac{(Y_n - a_n)^2}{1 + (Y_n - a_n)^2}) \rightarrow 0$, 对任意 $\varepsilon > 0$, 令事件 $A = \{|Y_n - a_n| \geq \varepsilon\}$. 在 A 上有

$$f(|Y_n - a_n|) \geq \frac{\varepsilon^2}{1 + \varepsilon^2}$$

。因此

$$E[f(|Y_n - a_n|)1_A] \geq \frac{\varepsilon^2}{1 + \varepsilon^2} E(1_A) = \frac{\varepsilon^2}{1 + \varepsilon^2} P(A).$$

把这一项移到左侧, 就得到

$$\frac{\varepsilon^2}{1 + \varepsilon^2} P(|Y_n - a_n| \geq \varepsilon) \leq E f(|Y_n - a_n|).$$

再把系数 $\frac{1 + \varepsilon^2}{\varepsilon^2}$ 乘过去, 即得

$$P(|Y_n - a_n| \geq \varepsilon) \leq \frac{1 + \varepsilon^2}{\varepsilon^2} E \left[\frac{(Y_n - a_n)^2}{1 + (Y_n - a_n)^2} \right] \rightarrow 0,$$

故 $Y_n \xrightarrow{P} \lim a_n$, 即服从大数定律。

- * 必要性 (左推右): 若 $Y_n \xrightarrow{P} \lim a_n$, 对任意 $\varepsilon > 0$, 取 N 使 $n > N \Rightarrow P(|Y_n - a_n| \geq \varepsilon) \leq \varepsilon$ 。利用 $0 < f(t) < 1$ 、且 f 单调, 拆两块:

$$0 \leq Ef(Y_n - a_n) \leq f(\varepsilon)P(|Y_n - a_n| < \varepsilon) + 1 \cdot P(|Y_n - a_n| \geq \varepsilon) \leq \varepsilon^2 + \varepsilon,$$

任意小的 ε 使上界可逼近 0, 故期望极限为 0。

- ★★★★★ 设 X_n 独立同分布、方差有限且非常数, $S_n = \sum_{i=1}^n X_i$ 。证明序列 $\{S_n\}$ 本身不服从大数定律 (不可能依概率收敛到某常数)。

* 可设 “累计和的累计” $T_n = \sum_{i=1}^n S_i = \sum_{k=1}^n (n+1-k)X_k$ 以便放大方差。

* 假如 $\{S_n\}$ 服从大数定律, 则对任意 $\varepsilon > 0$, 有 $P(|T_n - E(T_n)| \geq n\varepsilon) \rightarrow 0$ 。取大 n 使该概率 $< \varepsilon^2/\sigma^2$, 记事件 $A = \{|T_n - E(T_n)| < n\varepsilon\}$ 。

* 用方差分解:

$$\text{Var}(T_n) = E[(T_n - E(T_n))^2] = P(A)E[(T_n - E(T_n))^2 | A] + P(\bar{A})E[(T_n - E(T_n))^2 | \bar{A}].$$

在 A 内平方至多 $n^2\varepsilon^2$; 在 $\bar{A}$ 内粗放上界为 $(\sigma n^{3/2})^2$ 的数量级, 可直接取 $\sigma^2 n^3$ 。于是

$$\text{Var}(T_n) \leq n^2\varepsilon^2 + P(\bar{A})\sigma^2 n^3 \leq n^2\varepsilon^2 + \varepsilon^2 n^3 \leq 2n^3\varepsilon^2.$$

* 另一方面直接算方差: $\text{Var}(T_n) = \sum_{k=1}^n (n+1-k)^2 \sigma^2 = \sigma^2 \frac{n(n+1)(2n+1)}{6}$, 介于 $\frac{\sigma^2 n^3}{3}$ 与 $\sigma^2 n^3$ 之间。若取 $2\varepsilon^2 < \sigma^2/3$, 则上界 $2n^3\varepsilon^2$ 与下界 $\frac{\sigma^2 n^3}{3}$ 矛盾, 因此假设不成立, $\{S_n\}$ 不服从大数定律。

4.4 中心极限定理

主要内容: 独立同分布的中心极限定理、常用正态近似套路 (含二项/泊松到正态), 以及 “看到独立小扰动求和就想 CLT” 的应试判断。

• 知识点:

- 经典 CLT (i. i. d. 版): X_i 独立同分布, $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 < \infty$, 则 $\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$ 。

- 正态近似套路: 先列出和/均值的均值与方差; 标准化成 Z ; 再用正态分布求概率。二项 $b(n, p)$ 近似 $N(np, np(1-p))$, 泊松 λ 大时近似 $N(\lambda, \lambda)$ 。连续性修正如需可在整数端点加/减 0.5。

• 典型例题:

- ★★☆☆☆ 计算机每次取整的误差服从分布 $U_i \sim U(-0.5, 0.5)$ 且独立, 同分布。

1) 若将 1500 个数相加, 求误差总和 S 的绝对值超过 15 的概率。

* 单个误差均值 0, 方差 $\frac{1}{12}$ 。和的均值 0, 方差 $\frac{1500}{12} = 125$, 标准差 $\sigma_S \approx 11.18$ 。

* 标准化 $Z = S/\sigma_S$, $P(|S| > 15) = P(|Z| > 15/11.18 \approx 1.34)$ 。查标准正态表 $P(|Z| > 1.34) \approx 0.1802$ 。

2) 最多多少个数相加, 可使 $P(|S| < 10) \geq 0.9$?

* 要求 $P(|Z| < 10/\sigma_n) \geq 0.9 \Rightarrow \Phi(10/\sigma_n) - \Phi(-10/\sigma_n) \geq 0.9$, 利用对称得 $\Phi(10/\sigma_n) \geq 0.95$, 即 $10/\sigma_n \geq 1.645$ 。

* $\sigma_n = \sqrt{n/12}$, 故 $\sqrt{n/12} \leq 10/1.645 \approx 6.08$, 得到 $n \leq 12 \times 6.08^2 \approx 443.2$, 取整数上界 443。

- ★★☆☆☆ 抽样估计吸烟率。为确定某城市成年男子吸烟比例 p , 任意调查 n 人, 吸烟人数为 M 。求 n 至少多大才能保证 $P(|M/n - p| < 0.01) > 0.95$ 。

* $M \sim b(n, p)$, 样本频率 M/n 近似 $N(p, \frac{p(1-p)}{n})$ 。标准化: $\frac{M - np}{\sqrt{np(1-p)}} \approx N(0, 1)$ 。

* 要求 $P(|Z| < \frac{0.01\sqrt{n}}{\sqrt{p(1-p)}}) > 0.95$, 取最不利 $p(1-p)$ 最大值 0.25 ($p = 0.5$), 得

$$\frac{0.01\sqrt{n}}{0.5} \geq 1.96, \text{ 即 } n \geq \frac{(1.96)^2 \times 0.25}{0.0001} = 9604. \text{ 未知 } p \text{ 时用此上界保守满足要求。}$$

第五章 统计量及其分布

5.1 总体与样本

主要内容：总体/个体概念、样本与样本容量、抽样代表性、标记重捕的基本估计思路。

- 知识点：
 - 总体 = 研究对象的全体；个体 = 总体中单个元素；样本 = 从总体抽取的若干个体，样本容量 n 为样本大小。
 - 抽样的目标是用“少量、随机、能代表总体”的样本去推断总体特征；样本统计量（均值、方差等）是推断总体参数的工具。
 - 标记-重捕法（Lincoln-Petersen 估计）：第一次捕到并标记 n 条，放回充分混匀；第二次捕 m 条，其中重捕到标记 k 条。重捕的标记比例近似等于总体中标记比例，故总体规模估计为 $\hat{N} \approx \frac{n \times m}{k}$ 。前提是假设混匀、标记不脱落、捕捞对所有鱼等概率。
- 典型例题：
 - ★☆☆☆☆ 鱼塘估鱼量并识别总体与样本。第一次打捞 n 条刷红漆放回；一天后再捞 m 条，其中标记 k 条。
 - * 估计：用标记比例匹配，总体鱼数 $\hat{N} \approx \frac{n \times m}{k}$ 。直觉：重捕样本中标记占比 k/m 应接近总体标记占比 n/N 。
 - * 总体/样本：总体 = 鱼塘里所有鱼；第一次打捞的 n 条是“标记样本”；第二次打捞的 m 条是“调查样本”；其中 k 条是重捕的标记鱼。

5.2 经验分布与样本刻画（了解）

主要内容：经验分布函数、频数频率表、常用图形化工具（直方图、箱线图、茎叶图）用来直观描述样本。

- 知识点：
 - 经验分布函数 $F_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i \leq x\}}$ ，阶梯形，端点极限 $F_n(-\infty) = 0, F_n(+\infty) = 1$ 。
 - 频数/频率表：把数据分组，列出各组频数和频率，便于看集中趋势与离散程度。
 - 图形化：直方图看分布形状，箱线图看中位数/四分位/异常值，茎叶图保留原始数值结构。

5.3 统计量及其分布

主要内容：样本统计量（样本均值、样本方差、样本标准差、样本矩）、次序统计量与样本分位数、样本中位数与五数概括/箱线图；理解“样本版”与“总体版”的区别，尤其是样本方差分母 $n-1$ 的原因。

- 知识点：
 - 统计量：只含样本、无未知参数的函数，如样本均值 $\bar{X}$ 、样本方差 S^2 、次序统计量 $X_{(k)}$ 。
 - 样本均值： $\bar{X} = \frac{1}{n} \sum X_i$ ，是总体均值的无偏估计， $E(\bar{X}) = \mu$ ， $\text{Var}(\bar{X}) = \sigma^2/n$ （独立同分布时）。
 - 样本方差与“ $n-1$ ”： $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。分母用 $n-1$ 是因为一个自由度被样本均值估计“占用”，这样 $E(S^2) = \sigma^2$ （无偏）。若用 n ，期望为 $\frac{n-1}{n} \sigma^2$ 偏小。
 - 样本标准差 $S = \sqrt{S^2}$ ；样本原点矩、中心矩： $\frac{1}{n} \sum X_i^k, \frac{1}{n} \sum (X_i - \bar{X})^k$ 。
 - 次序统计量：将样本排序 $X_{(1)} \leq \dots \leq X_{(n)}$ ；样本分位数/中位数来自次序统计量；五数概括 = 最小值、下四分位、中位数、上四分位、最大值；箱线图展示集中趋势与尾部/异常值。
 - 抽样分布：统计量的分布。后续参数估计/假设检验里，样本均值、样本方差、比率等的抽样分布是检验和区间估计的基础。
- 典型例题：
 - ★☆☆☆☆ 设 $x_1, \dots, x_8$ 来自 $N(10, 9)$ ，求样本均值 $\bar{x}$ 的标准差。
 - * 已知总体均值 $\mu = 10$ ，总体方差 $\sigma^2 = 9$ ，样本容量 $n = 8$ 。
 - * 抽样分布：独立同分布正态样本下， $\bar{X} \sim N(\mu, \sigma^2/n)$ ，方差缩小到 σ^2/n 。
 - * 计算： $\text{Var}(\bar{X}) = 9/8$ ，故标准差 $\sqrt{9/8} = \frac{3}{\sqrt{8}} \approx 1.06$ 。

5.4 三大抽样分布

主要内容：卡方分布、t 分布、F 分布的来源、基本性质与常用变换；为什么在未知方差、比较方差/均值时需要这些分布；它们与正态/指数/参数估计、假设检验的联系。

• 知识点：

- 在总体正态且方差未知时，用样本方差标准化均值会引入 S ，比正态多一层不确定性，对应 t 分布；比较方差得到 F；卡方则是正态平方和或指数和的分布。
- 卡方：若 $Z_i \sim N(0, 1)$ 独立，则 $\sum_{i=1}^k Z_i^2 \sim \chi^2(k)$ 。可加性：自由度可直接相加。需要记忆的特例：若 $X \sim \text{Exp}(1/2)$ ，则 $X \sim \chi^2(2)$ （指数到卡方的变换）。
- t 分布： $t = \frac{Z}{\sqrt{U/k}}$ ， $Z \sim N(0, 1)$ ， $U \sim \chi^2(k)$ 独立。自由度 k 增大时趋近标准正态。用于“均值检验/区间”且方差未知。
- F 分布： $F = \frac{U/k_1}{V/k_2}$ ， $U \sim \chi^2(k_1)$ ， $V \sim \chi^2(k_2)$ 独立。性质：倒数关系 $1/F \sim F(k_2, k_1)$ ，可加性体现在分子分母自由度独立相加。用于比较两个方差或构造方差比的检验域。
- 与后续章节的联系：
 - * 参数估计：正态均值的区间估计用 t；方差区间用卡方；比值区间用 F。
 - * 假设检验：单样本/双样本 t 检验（均值）、卡方适合度/方差检验、F 检验（方差比、方差齐性）。

• 典型例题：

- ★★☆☆☆ 求 k 使 $P\left(\frac{(x_1 + x_2)^2}{(x_1 - x_2)^2 + (x_1 + x_2)^2} > k\right) = 0.05$ ，其中 $x_1, x_2 \sim N(0, 1)$ 独立。
 - * 设 $u = x_1 + x_2$ ， $v = x_1 - x_2$ ，线性变换的协方差： $E(uv) = E(x_1^2 - x_2^2) = 0$ ，进而可算得协方差为 0。且各自方差为 $\text{Var}(u) = 2, \text{Var}(v) = 2$ ，所以 u, v 独立且 $u, v \sim N(0, 2)$ 。
 - * 设法让分子/分母拆成卡方：因为 $u/\sqrt{2} \sim N(0, 1)$ ，所以 $(u/\sqrt{2})^2 \sim \chi^2(1)$ ；同理 $(u^2 + v^2)/2 \sim \chi^2(2)$ ，且二者独立。
 - * 组成 F：
$$\frac{u^2}{u^2 + v^2} = \frac{u^2/2}{(u^2 + v^2)/2} = \frac{\chi^2(1)}{\chi^2(2)} = \frac{1}{2} \cdot \frac{\chi^2(1)/1}{\chi^2(2)/2} = \frac{1}{2} F(1, 2).$$
- 因此：
$$\frac{(x_1 + x_2)^2}{(x_1 - x_2)^2 + (x_1 + x_2)^2} = \frac{1}{2} F(1, 2).$$
 - * 设 $W = \frac{u^2}{u^2 + v^2} = \frac{1}{2} F(1, 2)$ 。求 k 使 $P(W > k) = 0.05$ ，等价于 $P(F(1, 2) > 2k) = 0.05$ 。
 - * 查表：上侧 5% 分位 $F_{0.05}(1, 2) \approx 18.51$ ，故 $2k = 18.51 \Rightarrow k \approx 9.255$ 。
- ★★★☆☆ 设总体 $N(\mu, \sigma^2)$ ，样本 $x_1, \dots, x_{2n}$ ， $\bar{x} = \frac{1}{2n} \sum x_i$ ，求 $y = \sum_{i=1}^n (x_i + x_{n+i} - 2\bar{x})^2$ 的期望。
 - * 令 $z_i = x_i + x_{n+i}$ ，则 $z_i \sim N(2\mu, 2\sigma^2)$ 独立。由定义 $\bar{x} = \frac{1}{2n} \sum_{i=1}^{2n} x_i = \frac{1}{2n} \sum_{i=1}^n z_i$ ，故
$$2\bar{x} = \frac{1}{n} \sum z_i = \bar{z}.$$
 - * 代回： $y = \sum_{i=1}^n (z_i - \bar{z})^2 = (n-1)s_z^2$ ，其中 s_z^2 是 z_i 的样本方差（分母 $n-1$ ）。
 - * 无偏性： $E(s_z^2) = \text{Var}(z_i) = 2\sigma^2$ ，所以 $E(y) = (n-1) \cdot 2\sigma^2 = 2(n-1)\sigma^2$ 。
 - * 关键是要注意这里 z_i 也是导出来的样本，因此计算时需要用 $n-1$ 。
- ★★★☆☆ 设连续分布 F ，函数是严格的，样本 $x_1, \dots, x_n$ ，证明 $T = -2 \sum_{i=1}^n \ln F(x_i) \sim \chi^2(2n)$ 。
 - * 变换到均匀：连续严格单调的 F ，使得 $u_i = F(x_i) \sim U(0, 1)$ 独立。
 - * 指数到卡方：设 $v_i = -2 \ln u_i$ ，不难算得其分布函数 $P(v_i \leq t) = 1 - e^{-t/2}$ ($t > 0$)，即 $\text{Exp}(1/2)$ ，注意其等价于 $\chi^2(2)$ 。
 - * 最后，利用求和可加性： $T = \sum v_i$ 是 n 个独立 $\chi^2(2)$ 之和，因此 $T \sim \chi^2(2n)$ 。

第六章 参数估计

6.1 点估计及无偏性、有效性

主要内容：点估计量的定义；无偏性（均值对准真值）；有效性（无偏里比波动小）；常见无偏/有偏例子。

• 知识点：

- 点估计：用样本构造统计量 $\hat{\theta}(X_1, \dots, X_n)$ 来估计总体参数 θ 。
- 无偏性： $E(\hat{\theta}) = \theta$ 。有时简单“替换样本均值”可得无偏估计，如 $\bar{X}$ 估计总体均值，样本方差用 $n-1$ 保持无偏。
- 有效性：在无偏估计量族里，方差更小者更有效；同一参数，比较 $\text{Var}(\hat{\theta}_1)$ 和 $\text{Var}(\hat{\theta}_2)$ ，小者优。
- 典型例题：
 - ★★★★★ 指数样本，已知 $\bar{X}$ 是 $1/\lambda$ 的无偏估计，问 $1/\bar{X}$ 是否为 λ 的无偏估计？
 - * 背景： $X_i \sim \text{Exp}(\lambda)$, $E(X_i) = 1/\lambda$ ，所以 $\bar{X}$ 确实无偏估计 $1/\lambda$ 。
 - * 指数分布是伽马分布 $\text{Ga}(k, \lambda)$ 的特例（形状 $k=1$ ），独立指数样本求和会“叠加”形状参数，所以 $\sum X_i \sim \text{Ga}(n, \lambda)$ 。因此有 $n\bar{X} = \sum X_i \sim \text{Ga}(n, \lambda)$ 。
 - * 伽马密度回顾： $f(t) = \frac{\lambda^k}{\Gamma(k)} t^{k-1} e^{-\lambda t}$ ($t > 0$)； $k=1$ 时就是指数分布。
 - * 再做变量代换（因为实际要求的是 $\bar{X}$ ，而 $\bar{X} = t/n$ ），雅可比给一个额外的 n ，并把 t 全部换成 ny ，即可代表 $\bar{X}$ 的密度函数了：

$$f_{\bar{X}}(y) = f(ny) \cdot n = \frac{\lambda^n}{\Gamma(n)} (ny)^{n-1} e^{-\lambda ny} \cdot n = \frac{(\lambda n)^n}{\Gamma(n)} y^{n-1} e^{-\lambda ny}.$$

这里的变量代换非常重要，需要注意，服从 $\text{Ga}(n, \lambda)$ 的并不是 $\bar{X}$ 本身，而是 $n\bar{X}$ 。

$$E\left(\frac{1}{\bar{X}}\right) = \int_0^\infty \frac{1}{y} f_{\bar{X}}(y) dy = \frac{(\lambda n)^n}{\Gamma(n)} \int_0^\infty y^{n-2} e^{-\lambda ny} dy.$$

令 $t = \lambda ny$ ，则 $y = t/(\lambda n)$ ， $dy = dt/(\lambda n)$ ，积分变为

$$\frac{(\lambda n)^n}{\Gamma(n)} \int_0^\infty \left(\frac{t}{\lambda n}\right)^{n-2} e^{-t} \cdot \frac{dt}{\lambda n} = \frac{(\lambda n)^n}{\Gamma(n)} \cdot \frac{1}{(\lambda n)^{n-1}} \int_0^\infty t^{n-2} e^{-t} dt.$$

后半部分正是 $\Gamma(n-1)$ ，所以整体得到 $E(1/\bar{X}) = \frac{(\lambda n)^n}{\Gamma(n)} \cdot \frac{1}{(\lambda n)^{n-1}} \Gamma(n-1) = \frac{\lambda n}{\Gamma(n)} \Gamma(n-1) = \frac{\lambda n}{n-1}$ （用 $\Gamma(n) = (n-1)\Gamma(n-1)$ ）。

- * 结论：当 $n > 1$ ， $E(1/\bar{X}) = \frac{n}{n-1} \lambda > \lambda$ ，偏高； $n=1$ 时期望发散。故 $1/\bar{X}$ 有偏。
- ★★☆☆☆ 正态样本差分方差的无偏性：求 c 使 $c \sum_{i=1}^{n-1} (x_{i+1} - x_i)^2$ 无偏估计 σ^2 。
 - * 令 $d_i = x_{i+1} - x_i$ ，因 $x_i \sim N(\mu, \sigma^2)$ 独立，有 $d_i \sim N(0, 2\sigma^2)$ 。
 - * $E(d_i^2) = \text{Var}(d_i) = 2\sigma^2$ ，求和得 $E(\sum d_i^2) = 2(n-1)\sigma^2$ 。
 - * 要无偏： $c \cdot 2(n-1)\sigma^2 = \sigma^2 \Rightarrow c = \frac{1}{2(n-1)}$ 。
 - * 结论：取 $c = \frac{1}{2(n-1)}$ 可得到无偏估计。

6.2 替换原理与矩法估计、相合性

主要内容：矩估计思路（样本矩替换总体矩）；遇到多个参数就列同阶矩方程；相合性（样本量大时收敛正确）。

- 知识点：
 - 替换原理/矩法：用样本矩 $\frac{1}{n} \sum X_i^k$ 代替总体矩 $E(X^k)$ ，解方程得到参数估计。
 - 相合性：估计量随 $n \rightarrow \infty$ 依概率收敛到真值（大样本“准”）。常见样本均值、样本方差都相合。
- 典型例题：
 - ★★☆☆☆ 矩估计。
 - * (1) 密度 $p(x; \theta) = \frac{2}{\theta^2}(\theta - x)$, $0 < x < \theta$ 。求矩估计。
 - 先算总体均值： $E(X) = \int_0^\theta x \frac{2}{\theta^2}(\theta - x) dx = \frac{\theta}{3}$ 。
 - 令样本均值 $\bar{x}$ 近似 $E(X)$ ，得 $\bar{x} \approx \frac{\theta}{3} \Rightarrow \hat{\theta} = 3\bar{x}$ 。
 - * (3) 密度 $p(x; \theta) = \sqrt{\theta} x^{\sqrt{\theta}-1}$, $0 < x < 1, \theta > 0$ 。求矩估计。

- 总体均值: $E(X) = \sqrt{\theta} \int_0^1 x^{\sqrt{\theta}} dx = \frac{\sqrt{\theta}}{\sqrt{\theta}+1}$ 。
- 令 $\bar{x} \approx E(X)$, 解方程 $\frac{\sqrt{\theta}}{\sqrt{\theta}+1} = \bar{x}$ 得 $\sqrt{\theta} = \frac{\bar{x}}{1-\bar{x}}$ (需 $0 < \bar{x} < 1$), 故 $\hat{\theta} = \left(\frac{\bar{x}}{1-\bar{x}}\right)^2$ 。

6.3 最大似然估计、EM、渐近正态性

主要内容: MLE 的定义与求解步骤; 边界/单调性注意; MLE 渐近正态且近似有效; 提到 EM 适用于含隐变量/缺失数据。

- 知识点:
 - 似然函数: $L(\theta) = \prod p(x_i; \theta)$, 对数似然便于求导。
 - 求解步骤: 写 L ; 取对数; 求导 $=0$ 解驻点; 检查定义域/边界。
 - 渐近性质: 正则条件下 $\hat{\theta}_{MLE}$ 渐近正态, 近似方差为费舍尔信息的倒数, 往往“渐近有效”。
 - EM (点到为止): 当有隐变量/缺失数据时, 用 E 步求条件期望, M 步最大化, 反复迭代逼近 MLE。
- 典型例题:
 - ★★☆☆☆ MLE。
 - * (1) $p(x; \theta) = \sqrt{\theta} x^{\sqrt{\theta}-1}, 0 < x < 1$, 求 MLE。
 - 似然: $L(\theta) = \theta^{n/2} (\prod x_i)^{\sqrt{\theta}-1}$ 。令 $t = \sqrt{\theta} > 0$, 则 $\ln L(t) = n \ln t + (t-1) \sum \ln x_i$ 。
 - 求导: $\frac{d}{dt} \ln L(t) = \frac{n}{t} + \sum \ln x_i = 0 \Rightarrow t = -\frac{n}{\sum \ln x_i}$ 。
 - 因 $0 < x_i < 1 \Rightarrow \sum \ln x_i < 0$, 故解出的 $t > 0$ 合法, MLE $\hat{\theta} = t^2 = \left(-\frac{n}{\sum \ln x_i}\right)^2$ 。(最好再检验一下二阶导为负, 证明是极大值)
 - * (2) $p(x; \theta) = \theta c^\theta x^{-(\theta+1)}, x > c > 0, \theta > 1$ 。求 MLE。
 - 对数似然:

$$\ln L(\theta) = \sum_{i=1}^n [\ln \theta + \theta \ln c - (\theta+1) \ln x_i] = n \ln \theta + n\theta \ln c - (\theta+1) \sum \ln x_i.$$

- 求导为零: $\frac{d}{d\theta} \ln L = \frac{n}{\theta} + n \ln c - \sum \ln x_i = 0$ 。解得 $\hat{\theta} = \frac{n}{\sum \ln x_i - n \ln c}$ 。因 $x_i > c \Rightarrow \ln x_i > \ln c$, 分母为正。但最好需检验定义域 $\hat{\theta} > 1$ 。(最好再检验一下二阶导为负, 证明是极大值)

- ★★☆☆☆ 为了估计湖中有多少条鱼, 捞出 1000 条标上记号后放回, 再捞出 150 条, 其中有 10 条有记号。问湖中有多少条鱼, 才能使 150 条鱼中出现 10 条带记号的鱼的概率最大?

* 精确似然 (超几何): $L(N) = \frac{C_{1000}^{10} C_{N-1000}^{140}}{C_N^{150}}$ 。

* 用比值判定单调: 设 $A_N = \frac{L(N)}{L(N-1)}$ 。利用组合恒等式 $\frac{C_n^k}{C_{n-1}^k} = \frac{n}{n-k}$, 得

$$A_N = \frac{C_{N-1000}^{140}}{C_{N-1001}^{140}} \cdot \frac{C_{N-1}^{150}}{C_N^{150}} = \frac{N-1000}{N-1140} \cdot \frac{N-150}{N}.$$

* 判断方向: $A_N > 1 \iff (N-1000)(N-150) > (N-1140)N \iff N < 15000$; $A_N < 1$ 则 $N > 15000$; $A_{15000} = 1$ 。

* 结论: 似然随 N 增大先升后降, 极大值在 $N = 15000$ 。

6.6 区间估计

主要内容: 枢轴量法构造置信区间; 单总体正态均值/方差区间 (方差已知/未知); 两个正态总体的均值差、方差比区间; 大样本近似区间; 样本量按误差反推。

- 知识点:
 - 区间估计与置信区间: 用一个区间估计未知参数, 并给出区间包含真值的可信程度 (置信水平)。若统计量 θ_L, θ_U 满足 $P(\theta_L \leq \theta \leq \theta_U) = 1 - \alpha$, 则 $[\theta_L, \theta_U]$ 是参数 θ 的 $1 - \alpha$ 置信区间。

- 枢轴量法 (总体的方法): 寻找一个含参数的统计量 $G(X_1, \dots, X_n; \theta)$, 其分布已知且不依赖未知量, 对不等式两边同时作用分位数, 反解出参数的置信区间。
- 单个正态总体参数的置信区间: (背诵公式)
 - 1) 均值 μ 、方差都已知: 用正态分布, $\bar{x} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$;
 - 2) 均值 μ 已知、方差未知: 用 t 分布, $\bar{x} \pm t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}}$;
 - 3) 方差 σ^2 已知 (均值未知): 用卡方分布, $(\frac{(n-1)s^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)s^2}{\chi_{\alpha/2}^2(n-1)})$ 。
- 两个正态总体参数的置信区间: (背诵公式)
 - * 均值差 $\mu_1 - \mu_2$ 已知, 方差已知: 用正态分布, $(\bar{x} - \bar{y}) \pm z_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$ 。
 - * 均值差 $\mu_1 - \mu_2$ 已知, 方差未知但相等: 用合并方差 $s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}$, 标准误 $s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$, 最后计算区间时用 t 分布:

$$(\bar{x} - \bar{y}) \pm t_{1-\alpha/2}(n_1 + n_2 - 2) s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}.$$
 - * 方差比 σ_1^2/σ_2^2 : 用 F 分布, $(\frac{s_1^2/s_2^2}{F_{1-\alpha/2}(n_1-1, n_2-1)}, \frac{s_1^2/s_2^2}{F_{\alpha/2}(n_1-1, n_2-1)})$ 。
- 标准误: 和标准差并列, 是用来描述样本统计量 (如样本均值) 围绕总体参数 (如总体均值) 的变异程度, 反映抽样误差的大小。通常是样本标准差除以样本量 n 的平方根。
- 大样本近似: 非正态但 n 大, 可用 $\bar{X} \approx N(\mu, \sigma^2/n)$ 替换未知分布; 未知方差用样本方差代入。
- 样本量反推: 均值误差不超过 d 、置信 $1-\alpha$, 方差已知时 $n \geq (z_{1-\alpha/2}\sigma/d)^2$ (同理比例用 $p(1-p)$ 上界 0.25)。
- 典型例题:
 - ★★☆☆☆ 0.50, 1.25, 0.80, 2.00 是取自总体 X 的样本, 已知 $Y = \ln X \sim N(\mu, 1)$ 。
 - (1) 求 μ 的置信水平为 95% 的置信区间;
 - (2) 求 X 的数学期望的置信水平为 95% 的置信区间。
 * 解: 样本值 0.50, 1.25, 0.80, 2.00。令 $y_i = \ln x_i$, 得 $y_1 = -0.6931$, $y_2 = 0.2231$, $y_3 = -0.2231$, $y_4 = 0.6931$, 样本均值 $\bar{y} = 0$, $n = 4$ 。已知方差 1、置信 0.95, $z_{0.975} = 1.96$ 。
 - (1) 这里样本均值、总体方差都已知, 故用 $\frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ (本题 $\sigma = 1$)。代入公式:

$$\mu \in \bar{y} \pm z_{0.975} \frac{\sigma}{\sqrt{n}}.$$
 代入 $0 \pm 1.96 \times \frac{1}{2} = \pm 0.98$, 得区间 $(-0.98, 0.98)$ 。
 - (2) 由上一问, 可得 $E(X) = e^{\mu+1/2}$ 。这是因为: 若 $Y \sim N(\mu, \sigma^2)$, 则 $E(e^Y) = e^{\mu+\sigma^2/2}$ 。(常用结论, 可积分计算验证。直观理解: 指数把分布右拉, 均值比 e^μ 多出“半个方差”的补偿) 本题 $\sigma^2 = 1$, 所以 $E(X) = e^{\mu+1/2}$ 。把 μ 区间整体加 0.5 得 $(-0.48, 1.48)$, 再取指数: $(e^{-0.48}, e^{1.48}) = (0.6188, 4.3930)$ 。
 - ★★★☆☆ 材料抗压强度 $X \sim N(\mu, \sigma^2)$, 抽样 10 个: 482, 493, 457, 471, 510, 446, 435, 418, 394, 469。
 - (1) 求均值 μ 的 95% 置信区间 (σ 未知);
 - (2) 已知 $\sigma = 30$, 求均值 μ 的 95% 置信区间;
 - (3) 求 σ 的 95% 置信区间。
 * 解: $n = 10$, 样本均值 $\bar{x} = 457.5$ 。偏差平方和 = 11162.5, 样本方差 $s^2 = 1240.2778$, $s = 35.2164$ 。
 - (1) σ 未知, 用 t 枢轴量 $\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1)$ 。公式: $\mu \in \bar{x} \pm t_{0.975}(9) \frac{s}{\sqrt{n}}$ 。代入 $457.5 \pm 2.262 \times 11.137 = 457.5 \pm 25.19$, 得 $(432.31, 482.69)$ 。
 - (2) 已知 σ , 用正态枢轴量 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ 。公式: $\mu \in \bar{x} \pm z_{0.975} \frac{\sigma}{\sqrt{n}}$ 。代入 $457.5 \pm 1.96 \times 9.4868 = 457.5 \pm 18.59$, 得 $(438.91, 476.09)$ 。

- (3) 方差区间用 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。公式: $\sigma^2 \in (\frac{(n-1)s^2}{\chi_{0.975}^2(9)}, \frac{(n-1)s^2}{\chi_{0.025}^2(9)})$, 再开方得 σ 区间。代入 $\chi_{0.975}^2(9) = 19.0228$, $\chi_{0.025}^2(9) = 2.700$, 得 $\sigma^2 \in (586.67, 4134.26)$, 开方 $(24.22, 64.30)$ 。
- ★★★☆☆ $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 样本量 $n_1 = 10, n_2 = 15$, 样本统计 $\bar{x} = 82, s_1^2 = 56.5$; $\bar{y} = 76, s_2^2 = 52.4$ 。
- (1) 若已知 $\sigma_1^2 = 64, \sigma_2^2 = 49$, 求 $\mu_1 - \mu_2$ 的 95% 置信区间;
- (2) 求 σ_1^2/σ_2^2 的 95% 置信区间。

* 解:

- (1) 已知方差, 用正态枢轴量 $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1)$ 。公式: $(\mu_1 - \mu_2) \in (\bar{x} - \bar{y}) \pm z_{0.975} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$ 。代入标准误 $\sqrt{64/10 + 49/15} = 3.109$, 区间 $6 \pm 1.96 \times 3.109 = (-0.094, 12.094)$ 。
- (4) 方差比用 $F = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ 。公式: $\frac{\sigma_1^2}{\sigma_2^2} \in (\frac{s_1^2/s_2^2}{F_{1-\alpha/2}(9, 14)}, \frac{s_1^2/s_2^2}{F_{\alpha/2}(9, 14)})$ 。
- 代入 $s_1^2/s_2^2 = 1.0782$, $F_{0.975}(9, 14) \approx 3.01$, $F_{0.025}(9, 14) \approx 0.2632$, 得区间 $(1.0782/3.01, 1.0782/0.2632) \approx (0.358, 4.097)$ 。

第七章 假设检验

7.2 正态总体参数假设检验

- 知识点:
- 典型例题:

7.4 似然比检验与分布拟合检验

- 知识点:
- 典型例题: